



## QKI – Qualitätssicherung für KI-Systeme

### 4. Erklärbare KI

Prof. Dr. Alexander Maier

# Inhalte des Moduls

## 1. Grundlagen von Qualitätssicherung und -management

- I Aufgaben und Ziele von Qualitätsmanagementsystemen im Unternehmen
- I Werkzeuge und Verfahren der Qualitätsplanung, -lenkung, -prüfung und -verbesserung

## 2. Grundlagen der funktionalen Sicherheit bei technischen Systemen

- I Industriestandards, Zertifizierung
- I Technisch-organisatorische Maßnahmen

## 3. Validierung von maschinell gelernten Modellen

- I Herausforderungen beim Testen einer KI
- I Strategien und Frameworks zum systematischen Testen

## 4. Interpretierbare Modelle im maschinellen Lernen (Erklärbare KI, Explainable AI)

- I Informed Machine Learning
- I Strategien und Werkzeuge für Erklärbare KI

## 5. Zertifizierung einer KI

- I Anforderungen an KI und Zertifizierung
- I Praktische Umsetzung

# Inhalte Kapitel 4

## Erklärbare KI

### 4.1 Informed Machine Learning

- I Formalisierung von Wissen
- I Integration von Wissen

### 4.2 Terminologie zu Erklärbarer KI

- I Transparenz, Interpretierbarkeit, Erklärbarkeit

### 4.3 Erklärbare KI, Explainable AI (xAI)

- I Ziele der Erklärbarkeit
- I Black Box / White Box

### 4.4 Strategien und Werkzeuge für Erklärbare KI

## **Lernziele Kapitel 4**


### **Erklärbare KI**

Die Studierenden ...

- kennen Methoden des Informed Machine Learning und können Möglichkeiten beschreiben, verfügbares Wissen in Modelle zu integrieren,
- kennen die Grundlagen der Erklärbaren KI und können die Begriffe Transparenz, Interpretierbarkeit und Erklärbarkeit unterscheiden,
- kennen Methoden zur Erklärbaren KI aus dem Stand der Technik und sind in der Lage ausgewählte Methoden zu implementieren und in speziellen Anwendungen einzusetzen.

## Was ist erklärbare KI?

- I Clever Hans
- I Es ist nicht immer so,  
wie es aussieht...



<https://damn-8791.kxcdn.com/wp-content/uploads/2007/02/teaching-hans.jpg>

## A4.1.1: Was ist erklärbare KI?




- I Was müsste im Beispiel des Clever Hans genauer untersucht werden, um die „KI zu erklären“?
- I Warum ist es schwierig?

## 4.1 Informed Machine Learning

# Informed Machine Learning Definition

- I Lernen aus einer **hybriden Informationsquelle**
  - I **Daten und Vorkenntnis**
- I Die Vorkenntnisse sind vorhanden und von den Daten getrennt
- I Beides wird explizit in die Pipeline für maschinelles Lernen integriert



# Informed Machine Learning



- Haben Sie schon mal Vorwissen im Rahmen des Modelltrainings verwendet?
- Um welche Art von Wissen handelte es sich dabei?
- Wie wurde dieses Wissen integriert?
- Was war der Mehrwert?

# Informed Machine Learning - Taxonomy

## I Knowledge Source

- I Welche Wissensquelle ist integriert?


## I Knowledge Representation

- I Wie wird dieses Wissen dargestellt?

## I Knowledge Integration

- I Wo wird das Wissen in der Machine-Learning-Pipeline integriert?

# Informed Machine Learning - Taxonomy



# Informed Machine Learning - Taxonomy – Knowledge Source

## Naturwissenschaften

- I Subsummation von Fächern wie Naturwissenschaften, Technik, Ingenieurwissenschaften und Mathematik.
- I Wissen wird typischerweise **explizit durch wissenschaftliche Experimente validiert**
- I Beispiele
  - I universelle Gesetze der Physik
  - I biomolekulare Beschreibungen genetischer Sequenzen
  - I materialbildende Produktionsprozesse

# Informed Machine Learning - Taxonomy – Knowledge Source

## Sozialwissenschaften

- I Subsummation von Fächern wie Sozialpsychologie, Wirtschaftswissenschaften und Linguistik.
- I Solches Wissen wird oft **explizit durch empirische Studien validiert**
- I Beispiele
  - I Effekte in sozialen Netzwerken
  - I die Syntax und Semantik von Sprache

# Informed Machine Learning - Taxonomy – Knowledge Source

## Expertenwissen

- I Wissen, das von einem bestimmten Expertenkreis gehalten wird
  - I Innerhalb der Expertengemeinschaft kann es **auch als Allgemeinwissen** bezeichnet werden
- I Dieses Wissen kann **implizit von erfahrenen Spezialisten validiert** werden
- I Im Kontext der Kognitionswissenschaft kann dieses **Expertenwissen auch intuitiv** werden
  - I Ein Ingenieur oder Mediziner erwirbt zum Beispiel Kenntnisse aus mehrjähriger Tätigkeit in einem bestimmten Fachgebiet





# Informed Machine Learning - Taxonomy – Knowledge Source

## Weltwissen

- I Als Weltwissen bezeichnen wir **Tatsachen aus dem Alltag**, die fast jedem bekannt sind und daher auch als **Allgemeinwissen** bezeichnet werden können.
- I Solches Wissen kann **intuitiv und implizit von Menschen bestätigt** werden, die in der sie umgebenden Welt denken
- I Daher beschreibt Weltwissen oft **Beziehungen von Objekten oder Begriffen**, die in der vom Menschen wahrgenommenen Welt vorkommen
- I Beispiele
  - I Tatsache, dass ein Vogel Federn hat und fliegen kann
  - I Wenn es regnet, wird die Straße nass

# Informed Machine Learning - Taxonomy – Knowledge Representation

- I Illustrativer Überblick über **Wissensrepräsentationen** im Informed Machine Learning
- I Jede Darstellung wird durch einfache oder prominente Beispiele illustriert, um ein **erstes intuitives Verständnis der verschiedenen Typen** und ihrer Unterscheidung zu vermitteln.

| Algebraic Equations          | Logic Rules                | Simulation Results                                                                 | Differential Equations                                                                                   | Knowledge Graphs                                                                     | Probabilistic Relations                                                              | Invariances                                                                          | Human Feedback                                                                       |
|------------------------------|----------------------------|------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|
| $E = m \cdot c^2$ $v \leq c$ | $A \wedge B \Rightarrow C$ |  | $\frac{\partial u}{\partial t} = \alpha \frac{\partial^2 u}{\partial x^2}$ $F(x) = m \frac{d^2 x}{dt^2}$ |  |  |  |  |

## A4.1.2: Informed Machine Learning - Taxonomy – Knowledge Representation



- Überlegen Sie sich Beispiele für jede der Kategorien der Wissensrepräsentation.
- Wie können diese helfen, die „KI zu erklären“?

# Informed Machine Learning - Taxonomy – Knowledge Integration

## 4 Möglichkeiten der Wissensintegration

- I Training Data
- I Hypothesis Set
- I Learning Algorithm
- I Final Hypothesis

# Informed Machine Learning - Taxonomy – Knowledge Integration

## Training Data

- ! Eine **Standardmethode**, um Wissen in maschinelles Lernen zu integrieren
- ! Wissen wird in die zugrunde liegenden **Trainingsdaten** eingebettet
- ! klassischer Ansatz im traditionellen maschinellen Lernen: **Feature Engineering**
  - ! aus Know-how entsprechende Features erstellen
- ! informierter Ansatz: die Nutzung **hybrider Informationen** in Bezug auf
  - ! den **Originaldatensatz** und
  - ! eine zusätzliche, **separate Quelle von Vorwissen**
- ! Diese separate Vorwissensquelle ermöglicht es, Informationen zu sammeln und somit einen zweiten Datensatz zu erstellen, der dann zusammen mit oder zusätzlich zu den ursprünglichen Trainingsdaten verwendet werden kann
- ! Ein prominenter Ansatz ist das **simulationsgestützte maschinelle Lernen**, bei dem die Trainingsdaten durch Simulationsergebnisse ergänzt werden

# Informed Machine Learning - Taxonomy – Knowledge Integration

## Hypothesis Set

- I Die **Integration von Wissen in den Hypothesensatz** ist beispielsweise durch die Definition der Architektur eines neuronalen Netzes und der Hyperparameter üblich
  - I Beispielsweise wendet ein neuronales Faltungsnetzwerk Wissen bezüglich der Orts- und Übersetzungsinvarianz von Objekten in Bildern an
- I Allgemeiner kann Wissen integriert werden, indem die **Modellstruktur gewählt** wird
  - I Ein bemerkenswertes Beispiel ist der Entwurf einer Netzwerkarchitektur unter Berücksichtigung einer Abbildung von Wissenselementen, wie beispielsweise Symbolen einer Logikregel, auf bestimmte Neuronen.

# Informed Machine Learning - Taxonomy – Knowledge Integration

## Lernalgorithmus

- I Lernalgorithmen beinhalten typischerweise eine **Verlustfunktion** (Loss Function), die gemäß zusätzlichem Wissen **modifiziert** werden kann, z.B. durch das Entwerfen eines geeigneten Regularisierers.
- I Ein typischer Ansatz des informierten maschinellen Lernens ist, dass Vorwissen in Form von algebraischen Gleichungen, beispielsweise physikalischen Gesetzen, durch zusätzliche Verlustterme integriert wird.

# Informed Machine Learning - Taxonomy – Knowledge Integration


## Final Hypothesis

- I Der Output einer Lernpipeline, d.h. die finale Hypothese, kann **mit vorhandenem Wissen verglichen** werden.
- I Vorhersagen, die nicht mit bekannten Einschränkungen übereinstimmen, können beispielsweise verworfen oder als verdächtig markiert werden, damit die Ergebnisse mit dem Vorwissen übereinstimmen.

# Informed Machine Learning Nutzung der Taxonomie zur Wissens-Integration

Beispiel für einen **Taxonomiepfad**


- Es zeigt die Nutzung naturwissenschaftlicher Erkenntnisse in Form von algebraischen Gleichungen auf, die dann in den Lernalgorithmus integriert werden.



# Informed Machine Learning

## Algebraische Gleichungen


- I **Algebraische Gleichungen** werden häufig verwendet, um **naturwissenschaftliches Wissen** darzustellen, können aber auch andere Formen von Expertenwissen verwenden
- I Naturwissenschaftliche Gleichungen, die in maschinelles Lernen integriert werden, stammen aus unterschiedlichen Bereichen, insbesondere aus der Physik, aber auch aus der Biologie, Robotik oder Produktionsprozessen.



# Informed Machine Learning


## Logische Regeln

- I **Logikregeln** können **Wissen aus verschiedenen Quellen** formalisieren
- I Am häufigsten wird das Wissen aus Welt- und Sozialwissenschaften verwendet gefolgt von den Naturwissenschaften.




## Informed Machine Learning Simulationsergebnisse

- Simulationsergebnisse beschreiben das **numerische Ergebnis einer Computersimulation**, die eine ungefähre Imitation des Verhaltens eines realen Prozesses ist.
- Eine Simulationsmaschine löst typischerweise einen mathematischen Modus mit **numerischen Methoden** und erzeugt **Ergebnisse für situationsspezifische Parameter**
- Das numerische Ergebnis ist das Simulationsergebnis, das wir hier als endgültige Wissensrepräsentation bezeichnen.
- Beispiele sind das Strömungsfeld einer simulierten Flüssigkeit oder Bilder simulierter Verkehrsszenen.




# Informed Machine Learning Differenzialgleichungen

- I **Differentialgleichungen** sind eine **Teilmenge algebraischer Gleichungen**, die Beziehungen zwischen Funktionen und ihren räumlichen oder zeitlichen Ableitungen beschreiben
- I Zwei berühmte Beispiele sind die Wärmegleichung, die eine partielle Differentialgleichung (PDE) ist, und das zweite Newtonsche Gesetz, eine gewöhnliche Differentialgleichung (ODE)
- I In beiden Fällen existiert eine (möglicherweise leere) **Menge von Funktionen**, die die Differentialgleichung **für gegebene Anfangs- oder Randbedingungen lösen**
- I sind oft die **Grundlage einer numerischen Computersimulation**.



# Informed Machine Learning Knowledge Graphs


- Ein Graph ist ein Paar  $(V, E)$ , mit  $V$  Knoten und  $E$  Kanten
- In einem Wissensgraphen beschreiben **Knoten normalerweise Konzepte**, während **Kanten (abstrakte) Beziehungen** zwischen ihnen darstellen (z.B. „Mann trägt Hemd“)
- In einem gewöhnlichen gewichteten Graphen quantifizieren Kanten die Stärke und das Vorzeichen einer Beziehung zwischen Knoten



# Informed Machine Learning


## Probabilistische Beziehungen

- I Das Kernkonzept **probabilistischer Beziehungen** ist eine **Zufallsvariable  $X$** , aus der **Stichproben  $x$**  gemäß einer zugrundeliegenden **Wahrscheinlichkeitsverteilung  $P(X)$**  gezogen werden können
- I Zwei oder mehr Zufallsvariablen  $X, Y$  können mit gemeinsamer Verteilung  $(x, y) \sim P(X, Y)$  voneinander abhängig sein
- I Vorkenntnisse können **Annahmen über die bedingte Unabhängigkeit** oder die **Korrelationsstruktur von Zufallsvariablen** oder sogar eine vollständige Beschreibung der **gemeinsamen Wahrscheinlichkeitsverteilungen** sein




# Informed Machine Learning Invarianzen

- I **Invarianzen** beschreiben Eigenschaften, die sich bei mathematischen **Transformationen wie Translationen und Rotationen nicht ändern**
- I Wenn ein geometrisches Objekt unter solchen Transformationen invariant ist, hat es eine Symmetrie (z.B. ein rotationssymmetrisches Dreieck)
- I Eine Funktion kann als invariant bezeichnet werden, wenn sie bei einer symmetrischen Transformation ihres Arguments das gleiche Ergebnis liefert



## Informed Machine Learning Feedback von Menschen

- I bezieht sich auf Technologien, die **Wissen über direkte Schnittstellen** zwischen Benutzern und Maschinen **transformieren**
- I Die Wahl der Eingabemodalitäten bestimmt die Art der Informationsübermittlung
- I Typische Modalitäten umfassen Tastatur, Maus und Touchscreen, gefolgt von Sprache und Computer Vision, z.B. Tracking-Geräte zur Bewegungserfassung
- I Theoretisch kann Wissen über Gehirn-Computer-Schnittstellen auch direkt über Gehirnsignale übertragen werden.
- I Im Vergleich zu anderen Kategorien in der Taxonomie ist die **Wissensrepräsentation durch menschliches Feedback weniger formalisiert**
- I es erschließt **Weltwissen und Expertenwissen**



## A4.1.3: Integration von Vorwissen und Erklärbarkeit



- I Inwiefern unterstützt die Integration von Vorwissen bei der anschließenden „Erklärbarkeit“?
- I Welche Alternativen gibt es?

## A4.1.4: Integration von Vorwissen und Qualitätssicherung



I Inwiefern trägt die Integration von Vorwissen zur Qualitätssicherung bei?

## A4.1.5: Informed Machine Learning

Wählen Sie eine Kategorie aus der Liste der möglichen Wissensrepräsentation und beschreiben Sie die Anwendung der Taxonomie zur Wissensintegration. Nehmen Sie dazu [von Rueden et al. 2020] zur Hilfe

- | Algebraische Gleichungen
- | Logische Regeln
- | Simulationsergebnisse
- | Differenzialgleichungen
- | Knowledge Graphs
- | Probabilistische Beziehungen
- | Invarianzen
- | Feedback von Menschen



- Welche Daten werden verwendet?
- Welches Wissen wird integriert?
- Wie wird das Wissen integriert (Methoden etc.)?
- Demonstrieren Sie die Methode an einem Beispiel


[von Rueden et al. 2020]

von Rueden, Laura et al.: Informed Machine Learning - A Taxonomy and Survey of Integrating Knowledge into Learning Systems. (2020)

[https://www.researchgate.net/publication/339353315\\_Informed\\_Machine\\_Learning\\_-\\_A\\_Taxonomy\\_and\\_Survey\\_of\\_Integrating\\_Knowledge\\_into\\_Learning\\_Systems](https://www.researchgate.net/publication/339353315_Informed_Machine_Learning_-_A_Taxonomy_and_Survey_of_Integrating_Knowledge_into_Learning_Systems)

## 4.2 Terminologie zu Erklärbarer KI

## Transparenz, Interpretierbarkeit, Erklärbarkeit



[Roscher et al. 2020] Informed Machine Learning - A Taxonomy and Survey of Integrating Knowledge into Learning Systems  
[https://www.researchgate.net/publication/339353315\\_Informed\\_Machine\\_Learning\\_-\\_A\\_Taxonomy\\_and\\_Survey\\_of\\_Integrating\\_Knowledge\\_into\\_Learning\\_Systems](https://www.researchgate.net/publication/339353315_Informed_Machine_Learning_-_A_Taxonomy_and_Survey_of_Integrating_Knowledge_into_Learning_Systems)

## Transparenz, Interpretierbarkeit, Erklärbarkeit

Erklärung der Grafik der letzten Folie:

- I Die gebräuchliche, **einfache ML-Kette** (hellgraue Box) **lernt aus gegebenen Eingabedaten ein Black-Box-Modell** und stellt eine Ausgabe bereit.
- I Mit dem Black-Box-Modell und den **Input-Output-Beziehungen** kann ein **wissenschaftliches Ergebnis** abgeleitet werden, indem die Output-Ergebnisse unter Verwendung von Domänenwissen **erklärt** werden.
- I Alternativ kann ein **transparentes** und **interpretierbares** Modell anhand von **Domänenwissen** erklärt werden, das zu **wissenschaftlichen Ergebnissen** führt.
- I Darüber hinaus kann die **Einbindung von Domänenwissen** wissenschaftlich **konsistente Lösungen** fördern (grüne Pfeile).

## Terminologie

- I In der Literatur über erklärbare ML werden mehrere beschreibende Begriffe mit unterschiedlichen Bedeutungen verwendet
- I Dennoch lassen sich unterschiedliche Ideen erkennen
- I Hier Unterscheidung zwischen
  - I **Transparenz**
  - I **Interpretierbarkeit**
  - I **Erklärbarkeit**
- I Grob gesagt:
  - I **Transparenz** betrachtet den **ML-Ansatz**
  - I **Interpretierbarkeit** betrachtet das **ML-Modell** zusammen **mit Daten**
  - I **Erklärbarkeit** betrachtet das **Modell**, die **Daten** und die **menschliche Beteiligung**

# Transparenz

- I Ein ML-Ansatz ist **transparent**, wenn die Prozesse, die Modellparameter aus Trainingsdaten extrahieren und Labels aus Testdaten generieren, vom **Ansatzdesigner beschrieben und motiviert** werden können.
- I Transparenz eines ML-Ansatzes betrifft seine verschiedenen Bestandteile : Dazu gehören die gesamte **Modellstruktur**, die einzelnen **Modellkomponenten**, der **lernende Algorithmus** und wie der Algorithmus die **spezifische Lösung** erhält.
- I Unterscheidung zwischen
  - I **Modelltransparenz**
  - I **Designtransparenz**
  - I **algorithmischer Transparenz**
- I Im Allgemeinen ist es eher **unrealistisch**, von einer ML-Methode **in allen Aspekten** vollständige Transparenz zu erwarten; normalerweise gibt es unterschiedliche Transparenzgrade.

# Transparenz

- I Informell ist **Transparenz das Gegenteil von Opazität** oder „Black-Boxness“.
- I Es bedeutet ein gewisses Gefühl, **den Mechanismus zu verstehen**, nach dem das Modell funktioniert.
- I Betrachtung der Transparenz in unterschiedlichen Ebenen
  - I Ebene des **Gesamtmodells** (Simulierbarkeit)
  - I Ebene einzelner **Komponenten** wie Parameter (Zerlegbarkeit)
  - I Ebene des **Trainingsalgorithmus** (algorithmische Transparenz)

# Transparenz

- I Ein wichtiger Beitrag zum Verständnis von ML-Algorithmen ist **deren mathematische Interpretation und Ableitung**, die helfen zu verstehen, wann und wie diese Ansätze anzuwenden sind.
- I Klassische Beispiele sind der Kalman-Filter oder die Hauptkomponentenanalyse, für die mehrere mathematische Ableitungen existieren und deren Verständnis verbessern.

# Transparenz

- I **Transparenz** hängt in ihren drei Formen weitgehend **nicht von den konkreten Daten**, sondern **allein von der ML-Methode** ab
  - I (lediglich die erhaltene spezifische Lösung, insbesondere der „Lösungsweg“ dazu durch den (iterativen) Algorithmus, hängt von den Trainingsdaten ab)
- I Die **Analyseaufgabe und die Art der Attribute** spielen in der Regel eine Rolle, um eine Designtransparenz zu erreichen.
- I Darüber hinaus kann die Wahl der **Hyperparameter Modellstruktur, Komponenten oder den Algorithmus betreffen**, während bei einer algorithmischen Bestimmung von Hyperparametern wieder die spezifischen Trainingsdaten ins Spiel kommen.

# Transparenz

## Beispiel Kernel-basierte ML-Ansätze (1)

→ Das erhaltene Modell ist transparent, da es als Summe von Kernelfunktionen angegeben wird.

- I Die individuelle **Designkomponente** ist der gewählte Kernel.
  - I Die **Wahl zwischen einem linearen oder nichtlinearen Kernel** ist typischerweise eine **transparente** Designentscheidung.
  - I Die Verwendung des **gemeinsamen Gaußschen Kernels** basierend auf euklidischen Abständen kann jedoch eine **intransparente** Designentscheidung sein.
  - I Mit anderen Worten, es ist möglicherweise **nicht klar, warum** ein bestimmter nichtlinearer Kernel ausgewählt wurde.
- I Es können **domänenspezifische Designentscheidungen** getroffen werden, insbesondere unter Verwendung geeigneter Distanzmaße, um den euklidischen Abstand zu ersetzen, wodurch das Design dieser Modellkomponente (mehr) transparent wird.

# Transparenz

## Beispiel Kernel-basierte ML-Ansätze (2)

- I Im Fall der GP-Regression kann die spezifische Wahl des Kernels in die Optimierung der Hyperparameter unter Verwendung des Maximum-Likelihood-Frameworks eingebaut werden.
  - I Dabei geht Designtransparenz in algorithmische Transparenz über.
- Daher ist die **erhaltene spezifische Lösung aus mathematischer Sicht transparent**.
- I Es ist nämlich die einzigartige Lösung eines konvexen Optimierungsproblems, die reproduzierbar erhalten werden kann, was zu einer algorithmischen Transparenz führt.
- I Im Gegensatz dazu können Näherungen in der spezifischen Lösungsmethode wie frühes Stoppen, Matrix-Approximationen, stochastischer Gradientenabstieg und andere zu (einiger) Intransparenz des Algorithmus führen.

## A4.2.1: Transparenz von Neuronalen Netzen



Unter Berücksichtigung der gegebenen Definition für Transparenz:

- Sind Neuronale Netze transparent?

# Interpretierbarkeit

- I **Interpretierbarkeit:** dem erhaltenen ML-Modell einen **Sinn/Bedeutung** geben
- I Im Allgemeinen bedeutet interpretieren „**die Bedeutung von etwas erklären**“ oder „**in verständlichen Begriffen darstellen**“
- I **Erklären ist ein separater Aspekt** neben einer Interpretation
- I Ziel der Interpretierbarkeit ist es daher, einem Menschen einige Eigenschaften eines ML-Modells verständlich darzustellen.
- I Idealerweise Beantwortung der Frage: „**Können wir verstehen, worauf der ML-Algorithmus seine Entscheidung stützt?**“

# Interpretierbarkeit

Formale Definition nach [Montavon et al. 2018]:

- *Eine Interpretation ist die Abbildung eines abstrakten Konzepts (z.B. einer vorhergesagten Klasse) in eine Domäne, die der Mensch verstehen kann.*

[Montavon et al. 2018] G. Montavon, W. Samek, and K.-R. Müller, "Methods for interpreting and understanding deep neural networks," Digital Signal Processing, vol. 73, pp. 1–15, 2018

## Interpretierbarkeit


- I Interpretationen können über **verständliche Proxy-Modelle (Surrogat-Modelle)** gewonnen werden, die den Vorhersagen eines komplexeren Ansatzes nahe kommen.
- I Etablierte Ansätze beinhalten Entscheidungsbäume oder Regelextraktion und lineare Modelle.
- I Bei der **Prototypenauswahl** werden ein oder mehrere dem geprüften Datum **ähnliche Beispiele** ausgewählt, aus denen Kriterien für das Ergebnis abgeleitet werden können.
- I Für die **Merkmalswichtigkeit** werden die Gewichte in einem linearen Modell verwendet, um Attribute zu identifizieren, die entweder global oder lokal für eine Vorhersage relevant sind.

# Interpretierbarkeit

- I Z.B. **Modellagnostischer Ansatz LIME** (Local Interpretable Model-Agnostic Explanations)
  - I Erklärungen, die lokal mit einfachen, interpretierbaren Modellen gefunden werden und so ein annäherungsweise Verständnis von komplexen Machine Learning-Modellen möglich machen
  - I Die Sensitivitätsanalyse kann verwendet werden, um zu untersuchen, wie ein Modelloutput (lokal) von den verschiedenen Eingabeparametern abhängt.
- I Eine solche Extraktion von Informationen aus dem Input und dem Output eines gelernten Modells wird auch **Post-hoc-Interpretierbarkeit** oder **Reverse Engineering** genannt.

## Interpretierbarkeit

- I Visuelle Ansätze wie Salienzmasken oder Heatmaps zeigen **relevante Muster in der Eingabe** basierend auf **Merkmalswichtigkeit, Sensitivitätsanalyse oder Relevanzbewertungen** zur Erklärung von Modellentscheidungen
  - I insbesondere verwendet für Deep-Learning-Ansätze zur Bildklassifizierung



Lapuschkin, S., Wäldchen, S., Binder, A. et al. Unmasking Clever Hans predictors and assessing what machines really learn. Nat Commun 10, 1096 (2019).

# Interpretierbarkeit

- I Beim unüberwachten Lernen kann das **Analyseziel ein besseres Verständnis der Daten** sein.
  - I Zum Beispiel durch eine Interpretation der erhaltenen Darstellung durch lineare oder nichtlineare Dimensionsreduktion
- I Beachten Sie, dass im Gegensatz zur Transparenz **zur Erzielung der Interpretierbarkeit immer die Daten involviert** sind.
- I Obwohl es **modellagnostische Ansätze zur Interpretierbarkeit** gibt, kann Transparenz oder Beibehaltung des Modells bei der Interpretation hilfreich sein.
- I Darüber hinaus sind methodenspezifische Ansätze auf Transparenz angewiesen

# Interpretierbarkeit

## Anmerkung

- I Das interpretierbare und menschliche Verständnis der Leistung eines ML-Ansatzes kann später zu einer anderen Wahl des ML-Modells, des Algorithmus oder der Datenvorverarbeitung führen.

## A4.2.2: Interpretierbarkeit und Transparenz



- Erklären Sie mit eigenen Worten den Unterschied zwischen Interpretierbarkeit und Transparenz.
- Warum macht es Sinn, die beiden Begriffe zu unterscheiden?
- ... und wie sieht es mit Erklärbarkeit aus?

## Erklärbarkeit

- I Während die Forschung zu erklärbarem ML weithin als wichtig anerkannt wird, existiert **bislang noch kein gemeinsames Verständnis des Konzepts der Erklärbarkeit**.
- I In Bezug auf Erklärungen besteht zwischen ML und sogenannten Erklärungswissenschaften wie Rechts-, Kognitions-, Philosophie- und Sozialwissenschaften eine Erwartungslücke
- I Erklärungen können sich beispielsweise in der **Vollständigkeit** oder dem **Grad der Kausalität** unterscheiden

## Erklärbarkeit

- I Modell, das Erkenntnisse aus den Sozialwissenschaften mit Erklärungen in KI verknüpft
- I **Einteilung der erklärenden Fragen in drei Klassen** [Miller, 2019]

**Was** – Fragen, wie „Welches Ereignis ist passiert?“

**Wie** – Fragen wie „Wie kam es zu diesem Ereignis?“

**Warum** – Fragen wie „Warum ist dieses Ereignis passiert?“

[Miller, 2019] T. Miller, "Explanation in artificial intelligence: Insights from the social sciences," Artificial Intelligence, vol. 267, pp. 1–38, 2019.

# Erklärbarkeit

Mögliche Definition der erklärbaren KI nach [Montavon et al. 2018]:

- I Eine Erklärung ist die Sammlung von Merkmalen des interpretierbaren Bereichs, die für ein gegebenes Beispiel zu einer Entscheidung beigetragen haben (z.B. Klassifikation oder Regression).**

[Montavon et al. 2018] G. Montavon, W. Samek, and K.-R. Müller, "Methods for interpreting and understanding deep neural networks," Digital Signal Processing, vol. 73, pp. 1–15, 2018.

# Erklärbarkeit

## Anmerkung:

In Explainable AI **gehen diese und andere Definitionen implizit davon aus**, dass die **Konzepte**, die in den verständlichen Begriffen, die eine Erklärung bilden, ausgedrückt werden, **in sich abgeschlossen** sind und **keine weiteren Erklärungen benötigen**.

## Erklärbarkeit

- I Vermutung: eine Sammlung von Interpretationen kann nur mit weiteren **Kontextinformationen**, die aus **Domänenwissen** stammen und sich auf das Analyseziel beziehen, eine Erklärung sein.
  - I Mit anderen Worten: **Erklärbarkeit ist in der Regel nicht rein algorithmisch zu erreichen.**
- I **Allein die Interpretation eines Modells** – in für den Menschen verständlichen Worten – für ein individuelles Datum **kann keine Erklärung für das Verständnis der Entscheidung liefern.**
- I Insgesamt **hängt das Ergebnis vom zugrunde liegenden Analyseziel ab.**
- I "Warum wird die Entscheidung getroffen?" bedarf einer anderen Erklärung als „Warum unterscheidet sich die Entscheidung für Datum A von (dem nahegelegenen) Datum B?“.

## Erklärbarkeit

- I Für die Erklärbarkeit ist das **Ziel** des ML-„Benutzers“ **sehr relevant**.
- I im Wesentlichen vier Gründe, nach Erklärungen zu suchen:
  - I Entscheidungen zu begründen,
  - I Kontrolle zu (verbessern),
  - I Modelle zu verbessern und
  - I neues Wissen zu entdecken.
- I Für **regulatorische Zwecke** kann eine Erläuterung durch Beispiele oder (lokale) Merkmalsanalysen sinnvoll sein, um gewisse „formale“ Aspekte überprüfen zu können.
- I Aber um **wissenschaftliche Ergebnisse** mit ML zu erzielen, braucht man ein Verständnis.
  - I Hier nutzt der Wissenschaftler die **Daten**, die **Transparenz** der Methode und deren **Interpretation**, um die Ausgabeergebnisse (bzw. die Daten) mit **Domänenwissen** zu erklären und dadurch ein wissenschaftliches Ergebnis zu erzielen.

# Erklärbarkeit

## I Weiterhin Unterscheidung zwischen

### wissenschaftliche Erklärungen

Daten

Entitäten

Arten

Modelle

Theorien

→ keine vereinheitlichende allgemeine Darstellung der wissenschaftlichen Erklärung.

### algorithmische Erklärungen

Gründe für die Entscheidung eines ML-Verfahrens aufdecken

→ Ziel des erklärbaren ML

## Erklärbarkeit

- I Die Bedeutung der Begründung von Entscheidungen eines ML-Algorithmus ist auch für **medizinische Anwendungen** hoch, bei denen eine Motivation darin besteht, **Vertrauen in Entscheidungen** zu schaffen, so dass Patienten mit der getroffenen Entscheidung zufrieden sind.
- I All dies wird durch die **Datenschutz-Grundverordnung** unterstützt, die neue **Regeln zur Verwendung** personenbezogener Daten enthält.
  - I Ein Bestandteil dieser Regeln lässt sich unter dem Begriff „**Recht auf Erklärung**“ zusammenfassen
  - I Schließlich ist für ML-Modelle, die zur Entscheidungsunterstützung und Automatisierung eingesetzt werden, insbesondere in potenziell sich ändernden Umgebungen, eine zugrunde liegende Annahme, dass Robustheit und Zuverlässigkeit besser verstanden oder leichter realisiert werden können, wenn das Modell interpretierbar ist [Lipton, 2018].

[Lipton, 2018] Z. Lipton, "The mythos of model interpretability," Queue, vol. 16, no. 3, pp. 1–28, 2018

# Erklärbarkeit

Zu beachten ist auch, dass **mit Erklärungen manipuliert werden** kann.

- I Zur Veranschaulichung: Unterscheidung zwischen
  - I dem **intuitiven Wissenschaftler**, der versucht, die genaueste oder anderweitig optimale Entscheidung zu treffen, und
  - I dem **intuitiven Juristen**, der eine vorausgewählte Schlussfolgerung begründen möchte

# Domänenwissen

**Domänenwissen** ist ein **wesentlicher Bestandteil der Erklärbarkeit**

- I Dabei spielen drei Aspekte eine Rolle:
  - I Art des Wissens,
  - I Repräsentation und Transformation von Wissen und
  - I Integration von Wissen in den ML-Ansatz.
- I (Siehe Abschnitt Informed Machine Learning)

## A4.2.3: Terminologie



Untersuchen Sie für Ihr Szenario der Vorbereitungsaufgabe die Begrifflichkeiten


- | Transparenz
- | Interpretierbarkeit
- | Erklärbarkeit
- | Domänenwissen

## 4.3 Erklärbare KI, Explainable AI (xAI)

## Studie zu Erklärbare KI

[Kraus et al. 2021] Erklärbare KI: Anforderungen, Anwendungsfälle und Lösungen; Studie im Auftrag des Bundesministeriums für Wirtschaft und Energie (BMWi) im Rahmen der Begleitforschung zum Technologieprogramm „Künstliche Intelligenz als Treiber für volkswirtschaftlich relevante Ökosysteme“ (KI-Innovationswettbewerb)

<https://vdivde-it.de/de/publikation/erklaerbare-ki-anforderungen-anwendungsfaeelle-und-loesungen>



# Ziele der Erklärbarkeit von Künstlicher Intelligenz nach [Kraus et al. 2021]

## 1. Kausalitätsbeziehungen plausibilisieren

- I Mit erklärbarer KI sollen **Muster**, die durch KI entdeckt wurden, zusätzlich auf ihre **Gültigkeit und Plausibilität** geprüft werden.
- I Eine häufige Motivation ist das „**Finden**“ bzw. die Abbildung von **kausalen Zusammenhängen**.

# Ziele der Erklärbarkeit von Künstlicher Intelligenz nach [Kraus et al. 2021]

## 2. Übertragbarkeit testen

- I KI-Modelle werden in der Regel trainiert, um eine **spezifische Aufgabe** zu lösen, z.B. „finde alle Bilder mit einer Katze“.
- I Erklärbarkeit soll helfen, die **Übertragbarkeit** der gefundenen Lösung **auf neue Aufgaben** abzuschätzen (z.B. „finde alle Hunde“).
- I Dies hilft, den Anwendungsbereich und die **Grenzen einer KI zu bestimmen**.

## Ziele der Erklärbarkeit von Künstlicher Intelligenz nach [Kraus et al. 2021]

### 3. Informationsgewinn erhöhen

- I Informationen sollen zur Grundlage der Entscheidung in **verständlicher und einfacher**, aber **nicht zu sehr vereinfachter Form** bereitgestellt werden.
  - I Z.B. Informationen zur Funktionsweise des Modells
- I Ziel: die Entscheidung eines KI-Systems überhaupt als **Entscheidungsunterstützung** nutzen zu können

# Ziele der Erklärbarkeit von Künstlicher Intelligenz nach [Kraus et al. 2021]

## 4. Konfidenz bestimmen

Das KI-System soll überprüft werden auf:

### I **Robustheit**

- I Erhaltung von Gütekriterien des Systems bei Nichterfüllung von Annahmen oder statistischen Ausreißern

### I **Stabilität**

- I ähnliche Daten liefern ähnliche Ergebnisse

### I **Reproduzierbarkeit**

- I gleiches Ergebnis bei mehrmaliger Ausführung

Ziel: Anfälligkeiten und Gültigkeitsbereiche zu identifizieren

# Ziele der Erklärbarkeit von Künstlicher Intelligenz nach [Kraus et al. 2021]

## 5. Fairness testen

- I Bei diesem Ziel soll mithilfe erklärbarer KI die Möglichkeit geschaffen werden, ein Modell **auf Fairness zu überprüfen**
- I insbesondere durch Aufdecken eines möglicherweise **existierenden Bias** (d.h. einen systematischen Fehler) in der Datengrundlage.

# Ziele der Erklärbarkeit von Künstlicher Intelligenz nach [Kraus et al. 2021]

## 6. Interaktionsmöglichkeiten verbessern

- I Erklärbare KI soll die Nutzer dabei unterstützen, direkt **mit dem KI-System zu interagieren**
  - I insbesondere solche mit wenig KI-Expertise
- I z.B. um dessen Entscheidungsfindung oder die Verständlichkeit von Erklärungen zu verbessern, etwa über die **Bereitstellung alternativer Erklärungen**

## Ziele der Erklärbarkeit von Künstlicher Intelligenz nach [Kraus et al. 2021]

### 7. Privacy-Bewusstsein erhöhen

- I Potenziell kann erklärbare KI dem Nutzer einen **Einblick in die erfassten und gespeicherten Daten** ermöglichen
- I Dies soll zu einer **verstärkten Wahrnehmung von Privacy-Aspekten** führen

# Ziele der Erklärbarkeit von Künstlicher Intelligenz nach [Kraus et al. 2021]

## 8. Verantwortlichkeiten klären

- I Erklärbare KI kann zur **Klärung von Verantwortlichkeiten** und **Haftungsfragen** herangezogen werden.
- I Es kann z.B. über den Weg eines oder einer Sachverständigen bzw. eines Gutachtens festgestellt werden, dass in ein System absichtlich in großem Umfang Bias-behaftete Daten eingeschleust wurden, um dieses zu beeinflussen.

# Ziele der Erklärbarkeit von Künstlicher Intelligenz nach [Kraus et al. 2021]

## 9. Herstellen von Vertrauen

- I Ein zusätzliches Ziel, das in der Literatur ebenfalls häufig als Motivation formuliert wird, ist das **Herstellen von Vertrauen** („Trust-worthiness“).
- I das wird allerdings nicht mehr nur als übergeordnetes Ziel von Erklärbarkeit, sondern als **generelles Entwicklungsziel von KI-Systemen** angesehen.

## Trustworthy AI

Laut der Richtlinien der „High-Level Expert Group on AI“ der Europäischen Union für eine vertrauenswürdige Künstliche Intelligenz („trustworthy AI“) (High-Level Expert Group on AI 2019), **trägt Erklärbarkeit bereits per se zur Herstellung von Vertrauen bei.**

Die sieben Säulen, die das Vertrauen in KI stützen sollen:

- Vorrang menschlichen Handelns und menschlicher Aufsicht
- Technische Robustheit und Sicherheit
- Schutz der Privatsphäre und Datenqualitätsmanagement
- Transparenz (z. B. Nachverfolgbarkeit, Erklärbarkeit und Kommunikation)
- Vielfalt, Nichtdiskriminierung und Fairness
- Gesellschaftliches und ökologisches Wohlergehen
- Rechenschaftspflicht

<https://digital-strategy.ec.europa.eu/en/library/ethics-guidelines-trustworthy-ai>

## Was ist erklärbare KI?

Unterscheidung von **zwei Typen von Erklärungen**:

### Erklärungen von Einzelentscheidungen


- Entscheidungserklärungen, die dabei helfen, individuelle, datenbezogene Entscheidungen konkret nachzuvollziehen
- sogenannte **lokale** Erklärbarkeit oder Datenerklärbarkeit

### Erklärungen von Modellen bzw. Modellerklärungen

- Helfen, die Wirkzusammenhänge von KI-Modellen zu begreifen
- sogenannte **globale** Erklärbarkeit oder Modellerklärbarkeit
- z.B. lineare oder allgemein funktionale Zusammenhänge zwischen Eingangs- und Ausgangsgrößen.

## Was ist erklärbare KI?

Unterscheidung nach Stakeholder



## Zwei Arten der Erklärbaren KI

### I **eXplanation by Design (XbD)**

- I zielt darauf ab, ein Modell zu entwickeln, das für sich allein erklärbar ist
- I Verwendung von White-Box-Modellen


### I **Black Box eXplanation (BBX)**

- I oder Post-hoc-Erklärung
- I ein gegebenes Black-Box-Modell zielt darauf ab, seine Logik zu rekonstruieren
- I Nutzung von xAI-Verfahren zur Erklärung von Black-Box-Modellen

# Von der Black Box zur Erklärung

## Datenerklärbarkeit (lokal)


- Erklären, warum eine bestimmte Eingabe  $x$  zu bestimmter Ausgabe  $y$  führt



# Von der Black Box zur Erklärung

## Modellerklärbarkeit (global)


- I Erklären, wie ein bestimmtes Modell als Ganzes funktioniert
- I **Post-hoc:** Erklärung für eine Black Box erzeugen



# Von der Black Box zur Erklärung

## Modellerklärbarkeit (global)


- I Erklären, wie ein bestimmtes Modell als Ganzes funktioniert
- I **Ante-hoc:** Überführung eines Modells zur White Box, wodurch die Erklärung ermöglicht wird




# Von der Black Box zur Erklärung

## Ante-hoc Modellerklärbarkeit

I White Box-Modelle → Erklärbar „by nature“



Lineare Modelle



Entscheidungsbäume

**IF** temperature > 15 °C  
**AND** humidity < 60%  
**THEN** play tennis

**IF** wind = true  
**THEN** not play tennis

**IF** temperature < 10 °C  
**THEN** not play tennis

Regelsysteme

## 4.4 Strategien und Werkzeuge für Erklärbare KI

## Etablierte Strategien und Werkzeuge für Erklärbare KI

- I Einbindung von Prototypen
- I Einbindung von externen Wissensbasen
- I Surrogat-Modelle (Stellvertreter-Modelle)
- I Counterfactual Explanations
- I LIME (Local Interpretable Model Agnostic Explanations)
- I SHAP (SHapley Additive exPlanations)
- I Attribution Methods
  - I CAM / Grad-CAM / Grad-CAM++ (Gradient-weighted Class Activation Mapping)

## A4.4.1: Etablierte Strategien und Werkzeuge für Erklärbare KI



- I Ein Überblick aktueller Methoden ist hier gegeben:
  - I <https://vdivde-it.de/de/publikation/erklaerbare-ki-anforderungen-anwendungsfaelle-und-loesungen>
- I Wählen Sie eine Methode aus.
- I Bereiten Sie eine Präsentation vor, in der Sie die Funktionsweise beschreiben.
- I Implementieren Sie die Methode an einem realen Use Case (z.B. Ihre Vorbereitungsaufgabe).
- I Präsentieren Sie Ihre Ergebnisse anschließend in der Gruppe.

## A4.4.1: Etablierte Strategien und Werkzeuge für Erklärbare KI



- | Einbindung von Prototypen
- | Einbindung von externen Wissensbasen
- | Surrogat-Modelle (Stellvertreter-Modelle)
- | Counterfactual Explanations
- | LIME (Local Interpretable Model Agnostic Explanations)
- | SHAP (SHapley Additive exPlanations)
- | Attribution Methods
  - | CAM / Grad-CAM / Grad-CAM++ (Gradient-weighted Class Activation Mapping)
  - | LRP (Layer-Wise Relevance Propagation)
  - | IG (Integrated Gradients)
  - | DeepLIFT (Deep Learning Important FeaTures)
  - | Guided Backpropagation und Deconvolution / DeconvNet
  - | Activation Maximization
  - | Sensitivitätsanalyse

<https://vdivde-it.de/de/publikation/erklaerbare-ki-anforderungen-anwendungsfaelle-und-loesungen>

## A4.4.1: Etablierte Strategien und Werkzeuge für Erklärbare KI



An dieser Stelle: Präsentation der Projekte

# Einbindung von Prototypen

## Art der Erklärungen:

- I Entscheidungserklärungen
- I ein Modell liefert sowohl Entscheidung als auch Erklärung

## Anwendbar auf:

- I alle Modelle, unabhängig von deren konkreter Implementierung (aber mit Fokus auf Klassifikationsproblemen)
- I Bild- und Textdaten sowie numerische Daten

## Einbindung von Prototypen

### Beispiel:

- I Ein KI-Modell soll Patienten anhand ihrer Symptome einem Krankheitsbild zuordnen.
- I Für jedes Krankheitsbild, z. B. Erkältung, Grippe oder Lungenentzündung, wird ein Prototyp erstellt.
- I Dieser Prototyp fungiert als eine Art Steckbrief, der die jeweils häufig auftretenden Symptome zusammenfasst.
- I Die Prototypen können auf Grundlage der Symptome vieler verschiedener Patienten, die unter der entsprechenden Erkrankung leiden, erstellt werden.
- I Für jeden zu klassifizierenden Erkrankten wird nun ebenfalls ein Steckbrief erstellt, der die Symptome enthält, z. B. Husten, Fieber und Schnupfen. Dieser wird dann mit den Repräsentationen der einzelnen Klassen (Krankheitsbilder) verglichen und die ähnlichste herausgesucht.

# Einbindung von Prototypen

## Technischer Hintergrund:

- I Erzeugung der Repräsentationen einzelner Klassen zu erzeugen
  - I Beispielsweise Datenpunkte aus der Trainingsgrundlage, die die jeweilige Klasse gut beschreiben
  - I oder künstlich erzeugte Repräsentationen, die die für die jeweilige Klasse charakteristischen Merkmale umfassen.
- I Erzeugung der künstlichen Repräsentationen beispielsweise mit generativen Netzen wie Generative Adversarial Networks oder Variational Autoencoders.
- I Eine Klasse kann durch mehrere Prototypen charakterisiert werden.
- I Um eine Erklärung zu liefern, muss für ein Klassifikationsergebnis der ähnlichste Prototyp gefunden werden.
  - I beispielsweise mittels K-Nearest-Neighbor-Suche
- I Der Nutzer kann schließlich den verwendeten Prototyp für die konkrete Klasse sowie die eingegebenen Datenwerte vergleichen und so nachvollziehen, auf welcher Grundlage, also gemäß welcher Gemeinsamkeiten, die Entscheidung durch das KI-Modell getroffen wurde.

# Einbindung von Prototypen

## Vorteile:

- I Zahl der Prototypen kann frei gewählt werden
- I Intuitiv und leicht verständlich
- I Unabhängig vom KI-Modell und Datentypen

## Nachteile:

- I Unter Umständen Zahl der benötigten Prototypen unklar
- I Bei künstlich erzeugten Prototypen: eventuell nicht realistisch

(Molnar 2019; Barbalau et al. 2020; Li et al. 2017)

## Einbindung von Prototypen



- I Erstellen Sie ein Klassifikationsmodell, das Prototypen verwendet, um Krankheitsbilder anhand von Symptomen zu klassifizieren und eine Erklärung für die Entscheidung zu liefern.
- I **Datenvorbereitung:** Verwenden Sie einen Datensatz mit Symptomen und Krankheitsbildern (z. B. von Kaggle oder UCI). Die Symptome sollten numerisch oder kategorisch dargestellt werden.
  - I Z.B. <https://www.kaggle.com/datasets/uom190346a/disease-symptoms-and-patient-profile-dataset>
- I **Prototypen erstellen:** Berechnen Sie für jede Krankheit den Mittelwert oder Median der Symptome als Prototypen.
- I **Klassifikation:** Implementieren Sie einen K-Nearest-Neighbor (KNN)-Algorithmus, um für ein gegebenes Patientenprofil den nächsten Prototypen zu finden und die Krankheit zu klassifizieren.
- I **Erklärung:** Zeigen Sie für jede Vorhersage, welcher Prototyp als Grundlage diente und visualisieren Sie die Entscheidung (z. B. in einem Scatterplot).

# Einbindung von externen Wissensbasen

## Art der Erklärungen:

- I Entscheidungserklärungen
- I ein Modell liefert sowohl Entscheidung als auch Erklärung

## Anwendbar auf:

- I Alle Modelle, unabhängig von deren konkreter Implementierung (Fokus auf Klassifikationsprobleme)
- I nur Textdaten (Wissensbasis erforderlich)

## Einbindung von externen Wissensbasen

### Beispiel:

- I Die Datenbank PubMed enthält zahlreiche medizinische Artikel, die unter anderem konkrete Krankheiten und deren Symptome beschreiben.
- I Durch Nutzung dieser Wissensbasis kann ein KI-Modell die Zusammenhänge zwischen Symptomen und Krankheiten lernen.
- I Werden dem Modell anschließend Symptome von Patienten präsentiert, etwa eine starke Schwellung und ein Bluterguss am Knöchel sowie Schmerzen bei der Belastung, so könnte das Ergebnis des Modells „Verdacht auf Bänderriss“ sein.
- I Gleichzeitig erfolgt der Verweis auf einen oder mehrere Artikel aus PubMed, in denen genau diese Symptome und die Ableitung des entsprechenden Krankheitsbilds beschrieben sind und für die Anwender klar ersichtlich hervorgehoben werden.

# Einbindung von externen Wissensbasen

## Technischer Hintergrund:

- I Bei diesem Ansatz wird das KI-Modell (z. B. neuronale Netze) mit externen Wissensbasen kombiniert.
- I Die Wissensbasis wird bereits während des Trainings des KI-Modells genutzt, um das Modell zu erstellen.
- I Wissensbasen können beispielsweise Online-Publikationen zu einem bestimmten Thema, Fachbücher, Bedienungsanleitungen oder Wikipedia sein.
- I Ziel ist hierbei, Zusammenhänge aus den Wissensbasen zu lernen und vom KI-Modell getroffene Entscheidungen mit konkreten Einträgen in der Wissensbasis begründen zu können.

## Einbindung von externen Wissensbasen

### Vorteile:

- I Leicht nachvollziehbar: Verlässlichkeit der den Entscheidungen zugrundeliegenden Publikationen kann einfach geprüft werden
- I Kombination mehrerer Wissensbasen möglich

### Nachteile:

- I Abhängig von Qualität (und Vorhandensein) der Wissensbasis
- I Selbstständiger Aufbau einer qualitativen Wissensbasis ist sehr zeitaufwendig

(van Aken et al. 2021; Holzinger et al. 2017)

## Einbindung von externen Wissensbasen



- I Kombinieren Sie ein Klassifikationsmodell mit einer externen Wissensbasis, um eine Entscheidung zu treffen und diese mit einer verlässlichen Quelle zu erklären.
- I **Datenvorbereitung:** Wählen Sie einen Datensatz mit Symptomen und zugehörigen Krankheiten (z. B. von Kaggle oder UCI). Verwenden Sie Textdaten, die Symptome und Krankheitsbilder beschreiben.
  - I Z.B. <https://www.kaggle.com/datasets/uom190346a/disease-symptoms-and-patient-profile-dataset>
- I **Externe Wissensbasis einbinden:** Integrieren Sie eine externe Wissensbasis, die medizinische Artikel über Symptome und Krankheiten enthält. Z. B. ChatGPT, PubMed oder Wikipedia,
- I **Klassifikation:** Trainieren Sie ein Klassifikationsmodell (z. B. ein neuronales Netzwerk oder SVM), das die Symptome zu einer Krankheit klassifiziert.
- I **Erklärung:** Für jede Vorhersage liefert das Modell einen Bezug zu einem oder mehreren Artikeln aus der Wissensbasis, die die Entscheidung stützen. Visualisieren Sie die relevanten Textausschnitte aus der Wissensbasis, die die Diagnose erklären.

## Surrogat-Modelle (Stellvertreter-Modelle)

### Art der Erklärungen:

- I Bezogen auf das Ursprungsmodell weder Modell- noch Entscheidungserklärungen, da ein neues Modell erstellt wird
- I Post hoc

### Anwendbar auf:

- I Alle Modelle, unabhängig von deren konkreter Implementierung
- I Bild- und Textdaten sowie numerische Daten

## Surrogat-Modelle (Stellvertreter-Modelle)

### Beispiel:

- I Es wird ein nicht leicht verständliches KI-Modell trainiert, z. B. eine Support Vector Machine, um die täglichen Verleihzahlen für Wintersportausrüstung zu prognostizieren.
- I In das Modell fließen viele Faktoren ein, beispielsweise die Jahreszeit, der Wetterbericht, die Zeiten der Schulferien und der Wochentag.
- I Nun wird ein einfacheres Modell, etwa ein Entscheidungsbaum, trainiert, dessen Entscheidungen nachvollziehbarer sind, der aber nicht die komplette Komplexität des ursprünglichen Modells abbilden kann.
- I So sind die Prognosen des zweiten Modells oft ungenauer, doch es lassen sich allgemeingültige Regelmäßigkeiten ableiten wie: „Bei Nebel werden weniger Skier ausgeliehen“ oder „Montags ist die Zahl der Ausleihen deutlich geringer als Sonntags“.

# Surrogat-Modelle (Stellvertreter-Modelle)

## Technischer Hintergrund:

- I Bei der Erstellung von Surrogat-Modellen geht es darum, auf Grundlage eines Black-Box-Modells ein zweites Modell zu erstellen
  - I z. B. ein lineares Modell oder einen Entscheidungsbaum, das besser nachvollziehbar ist und zur Erklärung der Entscheidungen genutzt werden kann.
- I Aufbauend auf den Ein- und Ausgaben des ursprünglichen Modells, wird die Vorhersagefunktion des Surrogat-Modells abgeleitet.
- I So können Regeln aus trainierten neuronalen Netzen extrahiert und, darauf aufbauend, nachvollziehbare Entscheidungsbäume erstellt werden
  - I etwa mit dem Algorithmus TREPAN (Touretzky 1996).
- I Insbesondere für Bilddaten ist die Erstellung derartiger Bäume nicht trivial.

## Surrogat-Modelle (Stellvertreter-Modelle)

### Vorteile:

- I Sehr flexibel: Ursprüngliches und Surrogat-Modell können frei gewählt werden

### Nachteile:

- I Nur Approximation: Repräsentativität des Surrogat-Modells schwer messbar
- I Surrogat-Modell selbst kann sehr komplex und weniger nachvollziehbar werden
- I Nicht leicht auf Bilddaten anwendbar

(Adadi und Berrada 2018; Danilevsky et al. 2020; Molnar 2019)

## Surrogat-Modelle (Stellvertreter-Modelle)



- I Erstellen Sie ein Surrogat-Modell (z. B. Entscheidungsbaum), das ein komplexes Black-Box-Modell (z. B. Support Vector Machine) erklärt, indem es dessen Vorhersagen auf einfache Weise approximiert.
- I **Datenvorbereitung:** Wählen Sie einen Datensatz (z. B. zur Prognose von Fahrradverleihungen basierend auf Wochentag, Wetter, Jahreszeit). Der Datensatz sollte sowohl numerische als auch kategoriale Daten enthalten.
  - I Z.B. <https://www.kaggle.com/datasets/lakshmi25npathi/bike-sharing-dataset>
- I **Komplexes Modell:** Trainieren Sie ein komplexes Modell (z. B. Support Vector Machine), das die Prognosen erstellt.
- I **Surrogat-Modell erstellen:** Trainieren Sie ein einfacheres Modell (z. B. Entscheidungsbaum), das die Vorhersagen des ursprünglichen Modells approximiert.
- I **Erklärung:** Extrahieren Sie einfache Regeln aus dem Surrogat-Modell (z. B. „Bei Regen werden weniger Fahrräder ausgeliehen“) und erklären Sie damit die Vorhersagen des Black-Box-Modells.
- I **Visualisierung:** Visualisieren Sie den Entscheidungsbaum und heben Sie die wichtigsten Regeln hervor.

# Counterfactual Explanations

## Art der Erklärungen:

- I Entscheidungserklärungen
- I Post hoc

## Anwendbar auf:

- I Alle Modelle, unabhängig von deren konkreter Implementierung
- I Bild- und Textdaten sowie numerische Daten

# Counterfactual Explanations

## Beispiel:

- I Bei der Prüfung der Bewerbungen für eine Mietwohnung werden die Interessierten hinsichtlich mehrerer Kriterien bewertet und der geeignetste Interessent oder die geeignetste Interessentin ausgewählt.
  - I Beispielhaft werden hier die drei Faktoren Einkommen, Haustierbesitz und Schufa-Auskunft betrachtet.
- I Wird vom KI-System nun einem Interessenten mit einem Jahreseinkommen von 40.000 Euro, keinen Haustieren und einer positiven Schufa-Auskunft eine Absage erteilt, so wäre eine mögliche Erklärung:
  - I Bei einem Einkommen von 45.000 Euro kommt der Bewerber für eine Anmietung in Frage.
- I Genauso kann das Konzept bei einer positiven Entscheidung genutzt werden.
  - I Beispielhafte Erklärungen wären dafür: „Hätte der Bewerber oder der Bewerber eine Katze, käme er nicht als Interessent in Frage“ oder „Wäre die Schufa-Auskunft negativ, so kann er die Wohnung nicht mieten“.

# Counterfactual Explanations

## Technischer Hintergrund:

- I Counterfactual Explanations ist ein Konzept, das darauf abzielt, für ein konkretes Klassifikationsergebnis eine möglichst kleine Änderung in den Eingabewerten zu identifizieren, die zu einer Einteilung in eine andere Klasse führen würde. Es können mehrere dieser Änderungsmöglichkeiten existieren, die das Ergebnis gut erklären. Die folgenden vier Eigenschaften machen gute Counterfactual Explanations aus:
  - I Die ursprüngliche Entscheidung und die neu erzeugte sind sehr ähnlich
  - I So wenig Features wie möglich sollten verändert werden
  - I Mehrere unterschiedliche Erklärungen können hilfreich sein
  - I Die veränderten Features sollten realistisch sein
- I Praktische Umsetzungen adressieren nicht unbedingt alle dieser Anforderungen, sodass geprüft werden muss, welche dieser Punkte für den eigenen Anwendungsfall notwendig sind. Die Implementierung von Wachter et al. fokussiert beispielsweise nur auf die ersten beiden Anforderungen (Wachter et al. 2017). Dazu wird eine entsprechende Verlustfunktion aufgestellt, die hinsichtlich eines oder mehrerer Ziele optimiert wird.

# Counterfactual Explanations

## Vorteile:

- I Gut verständlich
- I Kein Daten- oder Modellzugriff erforderlich

## Nachteile:

- I Vorgeschlagene Änderung kann in der Praxis nicht realistisch oder gar unmöglich sein
- I Mehrere, sich widersprechende Erklärungen möglich

(Wachter et al. 2017; Stepin et al. 2021; Molnar 2019)

# Counterfactual Explanations



- I Implementieren Sie ein Modell, das für eine getroffene Entscheidung minimale Änderungen an den Eingabewerten identifiziert, die zu einer anderen Klassifikation führen würden.
- I **Datenvorbereitung:** Wählen Sie einen Datensatz (z. B. Bewerbung für eine Mietwohnung oder Kreditrückzahlung).
  - I Z.B. <https://www.kaggle.com/c/home-credit-default-risk/data>
- I **Modell:** Trainieren Sie ein Klassifikationsmodell, das eine Entscheidung trifft (z. B. Kredit wird zurückgezahlt oder nicht).
- I **Modell zur Erklärung:** Entwickeln Sie eine Methode, die minimale Änderungen an den Eingabewerten findet, die zu einer anderen Entscheidung führen (z. B. „Einkommen von 45.000 Euro statt 40.000 Euro hätte die Entscheidung geändert“).
- I **Erklärungen:** Bieten Sie mehrere mögliche Erklärungen für jede Entscheidung an.
- I **Hinweis:** Stellen Sie sicher, dass die vorgeschlagenen Änderungen realistisch sind

# **LIME** **(Local Interpretable Model-Agnostic Explanations)**

## **Art der Erklärungen:**

- I Entscheidungserklärungen
- I Post hoc

## **Anwendbar auf:**

- I Alle Modelle, unabhängig von deren konkreter Implementierung
- I Bild- und Textdaten sowie numerische Daten

## **LIME** **(Local Interpretable Model-Agnostic Explanations)**

### **Beispiel:**

- Berechnung der Sterbewahrscheinlichkeit von Krebspatienten abhängig vom Alter
  - Für eine 25-jährige Patientin wird als Ergebnis des KI-Modells eine Wahrscheinlichkeit von 45 Prozent angenommen.
  - Nun werden die Sterbewahrscheinlichkeiten für Patienten mit einem ähnlichen Alter, beispielsweise 24 (44 Prozent) und 26 Jahre (46 Prozent), berechnet
  - Anhand dieser drei Werte – in der Praxis werden üblicherweise mehr verwendet – ist es möglich, das Verhalten des Modells in einem begrenzten Rahmen einzuschätzen: z. B. ein leichter (linearer) Anstieg der Sterbewahrscheinlichkeit mit zunehmendem Alter.
- Für Patienten im Alter von 74, 75 und 76 Jahren kann sich das Modell anders verhalten – beispielweise einen deutlich stärkeren Anstieg der Sterbewahrscheinlichkeit mit zunehmendem Alter ausweisen
- So können mithilfe von LIME einzelne „Abschnitte“ des eigentlich stark verflochtenen und vielschichtigen Modells vereinfacht und so vom Nutzer besser nachvollzogen werden (Nguyen 2020).

# LIME

## (Local Interpretable Model-Agnostic Explanations)

### Technischer Hintergrund:

- I Grundidee von LIME ist das Erlernen eines lokal approximierten, interpretierbaren Modells für ein konkretes Klassifikations- oder Regressionsergebnis.
- I Dadurch kann mithilfe eines einfacheren, oft linearen Modells ein konkretes Ergebnis nachvollzogen werden
  - I obwohl das ursprüngliche Modell nur schwer nachvollziehbar ist.
- I LIME „sampelt“ mehrere Ergebnisse (bzw. Entscheidungen) und gewichtet diese entsprechend ihrer Nähe zum zu erklärenden Ergebnis.
- I Auf dieser Basis kann ein lokales Modell entwickelt werden, das mit den betrachteten Samples gut funktioniert und nachvollziehbar ist.

# **LIME** **(Local Interpretable Model-Agnostic Explanations)**

## **Vorteile:**

- Intuitiv und im Allgemeinen gut interpretierbar
- Schnell und einfach in bestehende Implementierungen integrierbar (entsprechendes Framework vorhanden)

## **Nachteile:**

- Problematisch bei ausgeprägt nichtlinearen Modellen
- Unter Umständen hohe Rechenzeit bei mehrdimensionalen Daten, z. B. Bilddaten
- Kaum reproduzierbar aufgrund Datensampling (eine mehrmals ausgeführte Klassifikation könnte unterschiedlich erklärt werden)

(Nguyen 2020; Ribeiro et al. 2016)

# LIME

## (Local Interpretable Model-Agnostic Explanations)



- I Implementieren und wenden Sie LIME an, um ein komplexes Modell zu erklären, indem Sie ein lokal approximiertes, interpretierbares Modell für ein Klassifikations- oder Regressionsergebnis erstellen.
- I **Datenvorbereitung** : Wählen Sie einen Datensatz (z. B. Titanic, Adult Income), um eine Klassifikationsaufgabe durchzuführen.
  - I Z.B. <https://www.kaggle.com/competitions/titanic>
- I **Modell**: Trainieren Sie ein komplexes Klassifikationsmodell (z. B. Random Forest, Support Vector Machine oder ein tiefes neuronales Netzwerk).
- I **Anwendung LIME**: Nutzen Sie das LIME-Framework, um das Modell zu erklären. Wählen Sie eine einzelne Vorhersage und approximieren Sie das Verhalten des Modells lokal um diese Vorhersage, indem Sie ein einfacheres Modell (z. B. lineares Modell) trainieren.
- I **Visualisierung**: Visualisieren Sie die wichtigsten Merkmale, die das Modell für die Vorhersage verwendet hat, und interpretieren Sie die lokale Erklärung.
- I **Vergleich und Analyse**: Analysiere Sie, wie gut das lokale Modell das komplexe Modell in diesem speziellen Bereich der Entscheidungsfindung approximiert.

# SHAP (SHapley Additive exPlanations)

## Art der Erklärungen:

- I Entscheidungserklärungen
- I Post hoc

## Anwendbar auf:

- I Alle Modelle, es existieren Optimierungen für einzelne Modelle (z. B. TreeSHAP für Random Forests)
- I Bild- und Textdaten sowie numerische Daten

## SHAP (SHapley Additive exPlanations)

### Beispiel:

- I Prognose des Einkommens anhand der drei Faktoren Alter, Geschlecht und Beruf
- I Es wird der **Einfluss jedes einzelnen Faktors auf ein konkretes Ergebnis** des KI-Systems bestimmt.
- I Um herauszufinden, wie wichtig das Alter für die Einkommensprognose ist, wird zuerst eine „normale“ Prognose unter Berücksichtigung von Alter, Geschlecht und Beruf berechnet.
- I Anschließend wird erneut eine Prognose erstellt, die jedoch nur die zwei Faktoren Geschlecht und Beruf nutzt.
- I So kann im Nachhinein der Unterschied zwischen den beiden Ergebnissen – einmal unter Berücksichtigung des Alters, einmal ohne Berücksichtigung des Alters – berechnet und der Einfluss des Faktors „Alter“ bestimmt werden.
- I Dieser Vorgang wird für die anderen beiden Faktoren wiederholt (Mazzanti 2020).

# SHAP (SHapley Additive exPlanations)

## Technischer Hintergrund:

- I Bei SHAP handelt es sich um einen Ansatz aus der Spieltheorie.
- I Bei der Anwendung der Methode wird jedes Feature bzw. jeder Inputwert im Hinblick auf ein konkretes Klassifikationsergebnis gewichtet.
- I Diese Gewichte werden auch als Shapley Values bezeichnet.
- I Die Idee dahinter ist, dass alle möglichen Kombinationen von Features beachtet werden, um die Wichtigkeit eines einzelnen Features zu bestimmen.
- I Jedem Eingabefeature wird so ein positiver oder negativer Wert zugeordnet, der den Einfluss des einzelnen Features auf das Ergebnis angibt.
- I Die Methode kann genutzt werden, um Entscheidungserklärungen zu generieren.
- I TreeSHAP ist eine Variante von SHAP, die besonders effizient auf baumbasierte Modelle angewendet werden kann.

# SHAP (SHapley Additive exPlanations)

## Vorteile:

- I Modellagnostisch (Variationen sorgen für hohe Effizienz)
- I Sehr präzise Erklärungen möglich
- I Gilt als industrieller Standard

## Nachteile:

- I Erklärungen nicht immer intuitiv
- I Eventuell hohe Rechenzeiten (vor allem bei Modellen mit hoher Parameterzahl)

(Molnar 2019; Lundberg und Lee 2017; Mangalathu et al. 2020; Mazzanti 2020; Bhatt et al. 2019)  
<https://arxiv.org/pdf/1705.07874.pdf>

# SHAP (SHapley Additive exPlanations)



- I Implementieren Sie SHAP, um zu verstehen, wie verschiedene Merkmale eines Modells zu einer spezifischen Vorhersage beitragen, und visualisieren Sie die Einflüsse einzelner Features.
- I **Datenvorbereitung** : Nutzen Sie einen Klassifikations- oder Regressionsdatensatz (z. B. Titanic, Adult Income, Housing Prices).
  - I Z.B. <https://www.kaggle.com/competitions/titanic>
- I **Modell**: Trainieren Sie ein beliebiges Modell (z. B. Random Forest, Gradient Boosting, oder ein neuronales Netzwerk) zur Vorhersage des Ziels.
- I **Anwendung SHAP**: Verwenden Sie das shap-Paket in Python, um den Einfluss jedes Features auf das Vorhersageergebnis für jedes einzelne Beispiel zu berechnen.
- I **Visualisierung**: Nutzen Sie die verfügbaren Visualisierungen wie `summary_plot`, `force_plot` und `dependence_plot`, um die Shapley-Werte und den Einfluss der Features zu visualisieren.
- I **Analyse**: Analysieren Sie, welche Merkmale den größten Einfluss auf das Vorhersageergebnis haben und wie sich die Features gegenseitig beeinflussen.

## Attribution Methods

- I Mithilfe sogenannter Attribution Methods wird der negative oder positive Einfluss von Teilen oder Bereichen der Eingabe eines KI-Modells auf dessen Ausgabe betrachtet (Sundararajan et al. 2017).
- I Dieser Gruppe können die folgenden konkreten Methoden zugeordnet werden:
  - I Sensitivitätsanalyse, LRP, DeepLIFT, Integrated Gradients, Grad-CAM, Guided Backpropagation und Deconvolution.
- I Hier wird stellvertretend nur CAM/ Grad-CAM betrachtet

# Attribution Methods

## Beispiel:

- I Bei der Bildklassifizierung geht es darum, Bildbereiche zu identifizieren, die ausschlaggebend für das Klassifikationsergebnis sind.
- I Beispielhaft sollen mithilfe eines neuronalen Netzes Objekte auf einem Bild erkannt werden.
- I Die beiden möglichen Klassen sind „Katze“ oder „Hund“.
- I Nachdem das KI-Modell eine Entscheidung, z. B. „Katze“, geliefert hat, wird der Einfluss einzelner Pixel und Bildbereiche auf die konkrete Entscheidung untersucht.
- I Dafür werden die einzelnen Bestandteile des neuronalen Netzes – Einheiten („Units“) und Schichten – betrachtet, um so die Ausgaben auf das Eingabebild zu „mappen“.
- I Es entsteht eine sogenannte Saliency Map, in der die Pixel und Bildbereiche, die einen besonders großen Einfluss darauf hatten, dass das Tier als Katze erkannt wurde, hervorgehoben sind.

## **Attribution Methods**

### **CAM / Grad-CAM / Grad-CAM++ (Gradient-weighted Class Activation Mapping)**

#### **Art der Erklärungen:**

- I Entscheidungserklärungen
- I Post hoc

#### **Anwendbar auf:**

- I Neuronale Netze, insbesondere Convolutional Neural Networks (für CAM ist u. U. das Hinzufügen spezieller Schichten notwendig)
- I Bilddaten

## **Attribution Methods**

### **CAM / Grad-CAM / Grad-CAM++ (Gradient-weighted Class Activation Mapping)**

#### **Technischer Hintergrund (1):**

- CAM ist eine Methode zur Visualisierung von ausschlaggebenden Regionen für ein konkretes Klassifizierungsergebnis eines neuronalen Netzes, insbesondere Convolutional Neural Network (CNN).
- Das Ergebnis ist eine Saliency Map, die über das ursprüngliche Bild gelegt werden kann und die betreffenden Regionen hervorhebt.
- Für die Erstellung der Saliency Map werden jeweils nur die letzten Schichten (Layer) des Netzes betrachtet.
- CAM ist nicht für jede Netzwerkarchitektur direkt anwendbar
  - unter Umständen muss diese durch Hinzufügen weiterer Schichten zuvor angepasst und dann das Netz neu trainiert werden.

# **Attribution Methods**

## **CAM / Grad-CAM / Grad-CAM++**

### **(Gradient-weighted Class Activation Mapping)**

#### **Technischer Hintergrund (2):**

- I Grad-CAM ist eine Generalisierung der CAM-Methode, erfordert kein erneutes Training des Modells und ist auf mehr Netzwerkarchitekturen anwendbar.
- I Ein Nachteil von Grad-CAM ist jedoch, dass nicht mehrere Vorkommen eines Objekts in einem Bild erkannt werden können.
- I Grad-CAM++ löst dieses Problem, sodass das Erkennen von mehreren Objektinstanzen in einem Bild möglich wird.

## **Attribution Methods**

### **CAM / Grad-CAM / Grad-CAM++ (Gradient-weighted Class Activation Mapping)**

#### **Vorteile:**

- Visualisierungen korrelieren mit menschlicher Aufmerksamkeit → leicht verständlich
- Gute Ergebnisse bei Aufgaben, in denen Bildobjekte lokalisiert werden müssen

#### **Nachteile:**

- Visualisierungen oft zu grob für kleine Bildobjekte → nur Grobvalidierung (Qualität stark von konkreter Anwendung abhängig)
- CAM: zusätzliche Layer müssen trainiert werden

(Zhou et al. 2015; Selvaraju et al. 2019; Chattopadhyay et al. 2017)

## Attribution Methods

### CAM / Grad-CAM / Grad-CAM++ (Gradient-weighted Class Activation Mapping)



- I Implementieren Sie Grad-CAM (oder Grad-CAM++) zur Visualisierung der wichtigsten Bildregionen, die für eine Klassifikation durch ein Convolutional Neural Network (CNN) entscheidend sind.
- I **CNN-Modell:** Nutzen Sie ein vortrainiertes Modell (z. B. VGG16, ResNet50) oder trainieren Sie ein einfaches CNN auf einem öffentlichen Datensatz wie CIFAR-10 oder ImageNet.
- I **Datensatz:** Verwenden Sie Bilddaten, auf denen das Modell Objekte klassifizieren soll (z. B. Hunde, Katzen, Autos, etc.).
- I **Anwendung von Grad-CAM:** Berechnen Sie die Gradienten der Zielklasse (z. B. "Katze" oder "Hund") in Bezug auf die letzten Schichten des CNNs und erstellen Sie die Saliency Map.
- I **Visualisierung:** Visualisieren Sie die Saliency Map auf dem Originalbild, um die entscheidenden Bildbereiche zu zeigen, die das Modell für die Klassifikation verwendet hat.
- I **Erklärung der Ergebnisse:** Interpretieren die Visualisierung und erklären Sie, welche Bildteile am wichtigsten für die Klassifikation waren und warum.

## Zusammenfassung

## Zusammenfassung

- I Informed Machine Learning unterstützt die Erklärbarkeit durch systematische Integration von Domänenwissen.
- I Taxonomy zum Informed Machine Learning unterscheidet nach:
  - I Knowledge Source
  - I Knowledge Representation
  - I Knowledge Integration
- I Der Begriff „Explainable AI“ umfasst verschiedene Aspekte, allgemein Unterscheidung zwischen
  - I Transparenz
  - I Interpretierbarkeit
  - I Erklärbarkeit
- I Es existieren unterschiedliche Methoden der Erklärbaren KI, allgemein Unterscheidung nach
  - I globaler (Modell-)Erklärbarkeit und
  - I lokaler (Entscheidungs-)Erklärbarkeit

## Literatur

- [Schaaf et al. 2021] Nina Schaaf, Saskia Johanna Wiedenroth, Philipp Wagner: Erklärbare KI in der Praxis – Anwendungsorientierte Evaluation von XAI-Verfahren; Studie (03/2021)
- [Kraus et al. 2021] Erklärbare KI: Anforderungen, Anwendungsfälle und Lösungen; Studie im Auftrag des Bundesministeriums für Wirtschaft und Energie (BMWi) (2021)
- [von Rueden et al. 2020] von Rueden, Laura et al.: Informed Machine Learning – A Taxonomy and Survey of Integrating Knowledge into Learning Systems. (2020)  
[https://www.researchgate.net/publication/339353315\\_Informed\\_Machine\\_Learning\\_-\\_A\\_Taxonomy\\_and\\_Survey\\_of\\_Integrating\\_Knowledge\\_into\\_Learning\\_Systems](https://www.researchgate.net/publication/339353315_Informed_Machine_Learning_-_A_Taxonomy_and_Survey_of_Integrating_Knowledge_into_Learning_Systems)
- [Roscher et al. 2020] Roscher et al.: Explainable Machine Learning for Scientific Insights and Discoveries;  
[https://www.researchgate.net/publication/339462248\\_Explainable\\_Machine\\_Learning\\_for\\_Scientific\\_Insights\\_and\\_Discoveries](https://www.researchgate.net/publication/339462248_Explainable_Machine_Learning_for_Scientific_Insights_and_Discoveries)
- [Brauschweig et al. 2021] Bertrand Braunschweig, Malik Ghallab (Editors): Reflections on Artificial Intelligence for Humanity; <https://link.springer.com/book/10.1007/978-3-030-69128-8>
- [Kraus et al. 2021] Tom Kraus, Lene Ganschow, Marlene Eisenträger, Steffen Wischmann: Erklärbare KI; Begleitforschung: iit-Institut für Innovation und Technik in der VDI/VDE Innovation + Technik GmbH; <https://vdivde-it.de/de/publikation/erklaerbare-ki-anforderungen-anwendungsaefaele-und-loesungen>



**Fragen?**