



QKI – Qualitätssicherung für KI-Systeme

5. Zertifizierung einer KI

Prof. Dr. Alexander Maier

Inhalte des Moduls

1. Grundlagen von Qualitätssicherung und -management

- I Aufgaben und Ziele von Qualitätsmanagementsystemen im Unternehmen
- I Werkzeuge und Verfahren der Qualitätsplanung, -lenkung, -prüfung und -verbesserung

2. Grundlagen der funktionalen Sicherheit bei technischen Systemen

- I Industriestandards, Zertifizierung
- I Technisch-organisatorische Maßnahmen

3. Validierung von maschinell gelernten Modellen

- I Herausforderungen beim Testen einer KI
- I Strategien und Frameworks zum systematischen Testen

4. Interpretierbare Modelle im maschinellen Lernen (Erklärbare KI, Explainable AI)

- I Informed Machine Learning
- I Strategien und Werkzeuge für Erklärbare KI

5. Zertifizierung einer KI

- I Anforderungen an KI und Zertifizierung
- I Praktische Umsetzung

Inhalte Kapitel 5

Zertifizierung einer KI

5.1 Notwendigkeit der KI-Zertifizierung

5.2 KI-Prüfkatalog

5.3 Prüfverfahren (Zertifizierung)

Lernziele Kapitel 5

Zertifizierung einer KI

Die Studierenden...

- können anhand der Kritikalitätspyramide beurteilen, ob eine weitergehende Analyse/ Zertifizierung der KI in einer spezifischen Anwendung notwendig ist,
- kennen die wesentlichen Dimensionen einer KI sowie die entsprechenden Risikogebiete,
- können anhand des Prüfkatalogs für eine gegebene Anwendung eine Risikoanalyse durchführen und notwendige Kriterien und Maßnahmen zur Sicherstellung der Anforderungen definieren.


5.1 Notwendigkeit der KI-Zertifizierung

Zertifizierung einer KI

Versuch einer Definition

- I Eine Zertifizierung ist eine **meist zeitlich begrenzte Bestätigung**, dass vorgegebene **Standards, Normen oder Richtlinien eingehalten** werden.
- I Diese Bewertung wird **von unabhängigen Dritten** (Zertifizierungsstellen) durchgeführt.
- I Grundlage sind unterschiedliche **national** oder auch **international** anerkannte und **gültige branchenabhängige Standards und Richtlinien**.
- I Es können sowohl Produkte und Dienstleistungen als auch Systeme, Prozesse und Personen zertifiziert werden.
- I **Meistens** erfolgt eine Zertifizierung auf **freiwilliger Basis**, um die Qualität des zertifizierten Gegenstands nachzuweisen
- I Im Bereich KI-Systeme existieren aktuell kaum gültige und anerkannte Standards und Normen, die konkret genug sind, um die Basis einer Zertifizierung bilden zu können.

Kritikalitätspyramide



A5.1.1: Notwendigkeit der Zertifizierung



- I Aus welchen Gründen ist eine Zertifizierung der KI notwendig?
- I Welche Potentiale bietet die Zertifizierung einer KI?
- I Nehmen Sie dazu (u.a.) diese Quellen zur Hilfe:

[Poretschkin et al. 2021]

Maximilian Poretschkin et al.: Leitfaden zur Gestaltung vertrauenswürdiger Künstlicher Intelligenz - KI-Prüfkatalog;
https://www.iais.fraunhofer.de/content/dam/iais/fb/Kuenstliche_intelligenz/ki-pruefkatalog/202107_KI-Pruefkatalog.pdf

[Heesen et al. 2020]

Jessica Heesen et al.: Zertifizierung von KI-Systemen – Impulspapier; Plattform Lernende Systeme; https://www.plattform-lernende-systeme.de/files/Downloads/Publikationen/AG3_Impulspapier_290420.pdf

5.2 KI-Prüfkatalog

KI-Prüfkatalog

[Poretschkin et al. 2021] Maximilian
Poretschkin et al.: Leitfaden zur
Gestaltung vertrauenswürdiger
Künstlicher Intelligenz - KI-Prüfkatalog;

https://www.iais.fraunhofer.de/content/dam/iais/fb/Kuenstliche_intelligenz/ki-pruefkatalog/202107_KI-Pruefkatalog.pdf



Interdisziplinäre Handlungsfelder für die Entwicklung einer KI-Zertifizierung

	Autonomie & Kontrolle	Ist eine selbstbestimmte, effektive Nutzung der KI möglich?	
	Fairness	Behandelt die KI alle Betroffenen fair?	
	Transparenz	Sind Funktionsweise und Entscheidungen der KI nachvollziehbar?	
	Verlässlichkeit	Funktioniert die KI zuverlässig und ist sie robust?	
	Sicherheit	Ist die KI sicher gegenüber Angriffen, Unfällen und Fehlern?	
	Datenschutz	Schützt die KI die Privatsphäre und sonstige sensible Informationen?	

<https://www.ki.nrw/flagships/zertifizierung/>

Dimension Fairness

- I Die Dimension Fairness soll sicherstellen, dass die KI-Anwendung **nicht zu ungerechtfertigter Diskriminierung** führt.
- I Typische Ursachen hierfür stellen unausgewogene (mit **Bias** behaftete) **Trainingsdaten** oder auch die **statistische Unterrepräsentation** von Personengruppen dar, welche zu einer verringerten Qualität der KI-Anwendung in Bezug auf diese Gruppen führen können.



Dimension Fairness

Risikogebiete:

I Fairness (FN)

- I Dieses Risikogebiet adressiert das Risiko, dass die KI-Anwendung **während der Entwicklung unfaires bzw. diskriminierendes Verhalten** gegenüber Nutzern oder Betroffenen lernt.

I Beherrschung der Dynamik (BD)

- I Dieses Risikogebiet behandelt Risiken hinsichtlich Fairness, die sich durch **Veränderungen der Rahmenbedingungen oder Änderungen im Nutzerverhalten** ergeben.

Dimension Autonomie und Kontrolle


Diese Dimension zielt auf zwei Dinge ab:

- I die **Autonomie der KI-Anwendung**
 - I zu beurteilen, welcher **Grad an Autonomie für die Anwendung** angemessen ist.
- I die **Autonomie des Menschen**
 - I zu untersuchen, ob der **Mensch** durch die KI-Anwendung **angemessen unterstützt** wird und **ausreichend Handlungsspielraum in der Interaktion** mit der KI-Anwendung erhält.



Einschub: Autonomie in der industriellen Produktion

https://www.plattform-i40.de/IP/Redaktion/DE/Downloads/Publikation/KI-industrie-40.pdf?__blob=publicationFile&v=10



Dimension Autonomie und Kontrolle

Risikogebiete:

- I **Angemessene und verantwortungsvolle** Gestaltung der **Aufgabenverteilung** zwischen Mensch und KI-Anwendung (GE)
 - I Dieses Risikogebiet behandelt Risiken, die sich aus **Einschränkungen der Nutzerautonomie** bzw. **unangemessener Autonomie der KI-Anwendung** ergeben.
- I Sicherstellung der **Informiertheit und Befähigung** von Nutzern und Betroffenen (IB)
 - I Dieses Risikogebiet adressiert Risiken, die dadurch entstehen, dass Nutzer und Betroffene **unzureichend über die KI-Anwendung**, deren **Nutzung** sowie die damit **verbundenen Risiken aufgeklärt** werden.

Dimension Transparenz

- I Unter diesem Oberbegriff sind Aspekte der **Nachvollziehbarkeit, Interpretierbarkeit, Reproduzierbarkeit und Erklärbarkeit** subsumiert.
- I Die Dimension Transparenz untersucht insbesondere
 - I ob die **grundlegende Funktionsweise der KI-Anwendung** für Nutzer und Experten **angemessen nachvollziehbar** ist,
 - I ob **Ergebnisse** der KI-Anwendung **reproduziert** und ggf. **begründet** werden können.



Dimension Transparenz

Risikogebiete (1):

I Transparenz gegenüber Nutzern und Betroffenen (NB)

- I Dieses Risikogebiet befasst sich mit Risiken, die dadurch entstehen, dass **Entscheidungen** und **Auswirkungen** der KI-Anwendung gegenüber **Nutzern und Betroffenen nicht hinreichend erklärt** werden können.

I Transparenz für Experten (EX)

- I Dieses Risikogebiet widmet sich Risiken, die dadurch entstehen, dass das Verhalten der **KI-Anwendung von einem Experten nicht hinreichend verstanden und nachvollzogen** werden kann.

Dimension Transparenz

Risikogebiete (2):

I Auditfähigkeit (AF)

- I Dieses Risikogebiet behandelt Risiken, die dadurch entstehen, dass die Entwicklung sowie die im Einzelfall ausgeführten Vorgänge im Betrieb der KI-Anwendung **nicht hinreichend dokumentiert** und belegt sind.

I Beherrschung der Dynamik (BD)

- I Dieses Risikogebiet behandelt Risiken, die dadurch entstehen, dass sich **Anforderungen** an die Transparenz oder die implementierten Transparenzverfahren selbst **ändern**.

Dimension Verlässlichkeit

- I Diese Dimension bezieht sich vornehmlich auf die **Qualität der KI-Komponente** und beurteilt u. a. deren **Robustheit**, d. h. die Konsistenz ihrer Ausgaben unter kleinen Veränderungen der Eingabedaten.
- I Neben der **Performanz** und **Robustheit** der KI-Komponente wird auch deren potenzielle **Ausgabe(un)sicherheit** betrachtet.



Dimension Verlässlichkeit

Risikogebiete (1):

I Verlässlichkeit im Regelfall (RE)

- I Dieses Risikogebiet behandelt das Risiko **fehlerhafter Vorhersagen** durch die KI-Komponente auf **regulären Eingabedaten**.

I Robustheit (RO)

- I Dieses Risikogebiet adressiert Risiken, die sich bei **störungsbehafteten oder manipulierten Eingabedaten** ergeben, für die jedoch eine korrekte Verarbeitung durch die KI-Komponente beabsichtigt ist.
- I Dabei werden sowohl **qualitative als auch quantitative Abweichungen** der Eingabedaten betrachtet, wie etwa Rauschen oder adversariale Beispiele.

Dimension Verlässlichkeit

Risikogebiete (2):

I Abfangen von Fehlern auf Modellebene (AF)

- I Dieses Risikogebiet behandelt Risiken aus **Eingabedaten, die nicht im Anwendungsbereich liegen** und für die eine korrekte Bearbeitung durch die KI-Komponente nicht zu erwarten ist. Diese sollen durch eine Detektionsstrategie abgefangen werden.

I Einschätzung von Unsicherheit (UN)

- I Dieses Risikogebiet betrachtet Risiken, die sich daraus ergeben, dass **keine Unsicherheitsschätzung bezüglich Ausgaben stattfindet**, oder, dass diese unrealistisch bzw. unbrauchbar ist.

I Beherrschung der Dynamik (BD)

- I Dieses Risikogebiet befasst sich mit dem Risiko, dass das in der KI-Komponente implementierte ML-Modell aufgrund von unbeabsichtigten **Model Drifts** oder **Veränderungen des Anwendungskontexts (Concept Drift)** Einbußen an Performanz oder hinsichtlich anderer Anforderungen erfährt.

Dimension Sicherheit

- I Diese Dimension adressiert sowohl Eigenschaften der Funktionalen Sicherheit als auch die **Absicherung gegenüber Angriffen und Manipulationen der KI-Anwendung.**
- I Die Maßnahmen in dieser Dimension beziehen sich primär auf die **Einbettung der KI-Komponente** und umfassen unter anderem **klassische Methoden der IT-Sicherheit.**



Dimension Sicherheit

Risikogebiete:

I Funktionale Sicherheit (FS)

- I Dieses Risikogebiet behandelt das Risiko **unbeabsichtigter Personen- oder Sachschäden**, die durch **Fehlfunktion** bzw. **Ausfall der KI-Anwendung** infolge mangelhaften Designs der Einbettung begünstigt oder gar verursacht werden.

I Integrität und Verfügbarkeit (IV)

- I Dieses Risikogebiet adressiert Risiken, die dadurch entstehen, dass die **für den Betrieb der KI-Anwendung relevanten Daten verfälscht** werden und dadurch die KI-Anwendung manipuliert wird und ggf. nicht mehr verfügbar ist.

I Beherrschung der Dynamik (BD)

- I Dieses Risikogebiet behandelt Risiken, die dadurch entstehen, dass **neue Gefährdungen** der genannten Risikogebiete auftreten oder **etablierte Verfahren an Effektivität verlieren**.

Dimension Datenschutz

- I Diese Dimension bezieht sich auf den **Schutz sensibler Daten** im Kontext von Entwicklung und Betrieb einer KI-Anwendung.
- I Dabei wird sowohl der **Schutz personenbezogener Daten** als auch von **Geschäftsgeheimnissen** adressiert.



Dimension Datenschutz

Risikogebiete:

I Schutz personenbezogener Daten (PD)

- I Dieses Risikogebiet behandelt Risiken, die mit der **nicht DSGVO-konformen Nutzung personenbezogener Daten** durch die KI-Anwendung verbunden sind, sowie das Risiko der **Re-Identifikation von Personen** in einem Datensatz.

I Schutz geschäftsrelevanter Information (GI)

- I Dieses Risikogebiet adressiert Risiken, die dadurch entstehen, dass **geschäftsrelevante Informationen** durch die KI-Anwendung **unerwünscht preisgegeben** werden.

I Beherrschung der Dynamik (BD)

- I Dieses Risikogebiet behandelt die Risiken, dass **neue Hintergrundinformationen** etwa zur Erstellung eines Personenbezugs entstehen, oder dass sich die **Anforderungen** an die Verarbeitung von Daten durch die KI-Anwendung **ändern**.

KI-Prüfkatalog

Anmerkung:

- I Zur besseren Übersichtlichkeit wird jeder Dimension und jedem Risikogebiet ein Kürzel zugeordnet.
- I Dieses wird später dazu verwendet, um u. a. Kriterien und Maßnahmen mit einer eindeutigen Kennung, einem alphanumerischen Identifier, zu versehen

Beispiel:

- I Die Dimension Fairness hat das Kürzel »FN«, das Risikogebiet »Beherrschung der Dynamik« in dieser Dimension das Kürzel »BD«.
- I Das erste Kriterium in diesem Risikogebiet hat im Prüfkatalog die Kennung [FN-R-BD-KR-01], wobei »R« für Risikogebiet und »KR« für Kriterium steht.

5.3 Prüfverfahren

Prüfverfahren


Der Prüfansatz des Katalogs gliedert sich in zwei Phasen.

1. Die **erste Phase** dient der **Operationalisierung von Qualitätskriterien**.
 - Hierzu werden KI-Risiken identifiziert und analysiert, und darauf basierend anwendungsspezifische Qualitätskriterien hergeleitet.
2. In der **zweiten Phase** wird eine **Absicherungsargumentation** für die KI-Anwendung entwickelt.
 - Unter Würdigung ergriffener, risikoabschwächender Maßnahmen sowie durchgeführter Tests wird die Erfüllung der Qualitätskriterien begründet.

Prüfverfahren

Top-Down

Risikobasierte
Herleitung
anwendungs-
spezifischer
Qualitätskriterien



Prüfverfahren - Schutzbedarfsanalyse

- I Abhängig von Aufgabe und Einsatzkontext der KI-Anwendung ist es möglich, dass nicht alle sechs Dimensionen gleichermaßen für die Bewertung der Vertrauenswürdigkeit relevant sind.
- I Daher wird **für jede Dimension** zunächst eine sogenannte **Schutzbedarfsanalyse** durchgeführt.
- I Ziel der Analyse ist es, den sogenannten „Schutzbedarf“ einer Dimension festzustellen.
- I Die Ermittlung des Schutzbedarfs orientiert sich an den **potenziellen Schäden**, die durch eine Fehlfunktion bzw. eine Verletzung von Anforderungen in Hinblick auf die betrachtete Dimension entstehen können.
 - I gering, mittel und hoch

Prüfverfahren - Risikoanalyse und Zielvorgaben

- I Wird für eine Dimension ein **mittlerer oder hoher Schutzbedarf** festgestellt, so ist die KI-Anwendung in Hinblick auf jedes der ihr untergeordneten Risikogebiete zu prüfen.
- I **Ziel:** festzustellen, welche der **potenziellen Risiken** des Risikogebiets für die spezifische KI-Anwendung **relevant** sind und **beherrscht** werden müssen.
- I Dazu werden zunächst die dem Risikogebiet zugehörigen Risiken in Anbetracht des Einsatzkontextes der KI-Anwendung ermittelt und eingeordnet.
- I Die identifizierten Risiken werden anschließend, ähnlich wie bei der Schutzbedarfsanalyse, anhand möglicher resultierender Schäden und Gefährdungen bewertet.
- I Basierend auf den als relevant identifizierten Risiken werden **Zielvorgaben** formuliert.
- I Die Zielvorgaben legen fest, unter welchen Umständen ein vertretbares Restrisiko in Hinblick auf das betrachtete Risikogebiet hergestellt ist.

Prüfverfahren - Risikoanalyse und Zielvorgaben

Anmerkung:

- I Die Auflistung von **Risiken im Katalog hat keinen Anspruch auf Vollständigkeit** und befreit den Entwickler oder Prüfer nicht von der Pflicht, weitere nicht aufgelistete Risiken zu erkennen und in der Risikoanalyse aufzugreifen.


Prüfverfahren - Kriterien zur Zielerreichung

- I Eine wichtige **Voraussetzung**, um das Erreichen der **Zielvorgaben objektiv überprüfen** zu können, ist es, **nachvollziehbare Kriterien** für deren Erreichen zu definieren.
- I Die Wahl einer **Metrik** zur Überprüfung von Qualitätseigenschaften ist **oft abhängig von der KI-Anwendung**, jedoch nicht beliebig.
- I Der KI-Prüfkatalog zeigt akzeptierte Metriken sowie Qualitätseigenschaften auf und bietet damit eine Orientierung bei der Wahl anwendungsspezifischer Kriterien.
- I In jedem Fall ist zu **begründen, warum diese für die betrachtete KI-Anwendung geeignet sind**.
- I KI-Anwendungen sind im Betrieb ggf. **veränderten Umgebungsbedingungen** ausgesetzt. Daher werden auch explizit Prüfanforderungen formuliert, die die Betriebsbedingungen der KI-Anwendung betreffen.
 - I Solche Zielvorgaben bzw. Kriterien finden sich insbesondere in den Risikogebieten mit dem Titel „Beherrschung der Dynamik“ wieder

Prüfverfahren

Bottom-Up

Argumentation für die Vertrauenswürdigkeit der KI-Anwendung basierend auf ergriffenen Maßnahmen



Prüfverfahren - Maßnahmen

- I Die Erfüllung der vorab definierten Kriterien ist zu belegen
- I Entlang des Lebenszyklus einer KI-Anwendung
 - I Daten
 - I KI-Komponente
 - I Betrieb
 - I Einbettung
- I Herausforderung, dass sich sowohl die **möglichen Gefährdungen**, die die Ursache für ein Risiko darstellen, als auch die **möglichen Maßnahmen** zur Minderung des Risikos aufgrund des **breiten Spektrums von KI-Anwendungen nicht vollständig darstellen lassen** und sich im Laufe der Zeit **weiterentwickeln**.
- I Es können auch **weitere Maßnahmen** ergriffen und dokumentiert werden, die nicht im Prüfkatalog adressiert sind;
 - I insbesondere solche, die KI-unspezifisch sind

Prüfverfahren - Maßnahmen

I Mögliche Formen der Maßnahmen

- I eine Dokumentation (Do)
- I ein Testbericht (Te)
- I die Beschreibung eines Prozesses (Pr)
- I oder eine Kombination daraus

- I Falls **eine Maßnahme zur Abschwächung verschiedenartiger Risiken** beiträgt, ist es nicht erforderlich, ein und dieselbe Dokumentation in mehreren Risikogebieten zu wiederholen, sondern es kann auf die in einem Risikogebiet vorhandene **Dokumentation verwiesen** werden.

Prüfverfahren - Gesamtbewertung (eines Risikogebietes)

- I Gesamtbewertung eines Risikogebietes, mit dem Ziel, unter Würdigung der dokumentierten Maßnahmen **nachzuweisen**, dass die **zuvor festgelegten Qualitätskriterien erfüllt sind**.
- I Darlegung, inwiefern die dokumentierten Maßnahmen, die durchgeführten Tests sowie die für den Betrieb vorgesehenen Prozesse wirksam sind, um die für dieses Risikogebiet formulierten Ziele zu erreichen.

Prüfverfahren - Zusammenfassende Betrachtung einer Dimension

- I Dimensionen mit mittlerem oder hohem Schutzbedarf werden zusammenfassend betrachtet.
- I insbesondere **mögliche Lücken** zusammentragen, die in den Gesamtbewertungen der einzelnen Risikogebiete identifiziert wurden.
- I Die verbleibenden **Restrisiken** werden angesichts des Schutzbedarfs der Dimension bewertet.

Prüfverfahren - Dimensionsübergreifende Beurteilung der Vertrauenswürdigkeit der KI- Anwendung

- I Ziel dieser Beurteilung ist es, mögliche Lücken in der Abschwächung von Risiken sowie potenzielle Trade-Offs zwischen den Dimensionen der Vertrauenswürdigkeit abzuwägen.
- I Darauf basierend wird ein Urteil über die Vertrauenswürdigkeit der KI-Anwendung gefällt und die Prüfung damit abgeschlossen.
- I Es ist möglich, dass Kriterien oder Maßnahmen zur Risikoabschwächung in der einen Dimension die Risiken in einer anderen Dimension, die ggf. sogar einen höheren Schutzbedarf hat, steigern. Dies erfordert Abwägung und wird in der dimensionsübergreifenden Beurteilung entsprechend diskutiert.
 - I Beispielsweise könnte eine Erhöhung der Transparenz zur Folge haben, dass es Angreifern ermöglicht wird, basierend auf neu verfügbaren Informationen effektivere und gezielte Angriffe auf die KI-Anwendung zu erstellen.

A5.3.1: Durchführung einer Zertifizierung (1)



Gruppenarbeit

- I Wählen Sie aus Ihrer Gruppe einen Use Case aus (z.B. Vorbereitungsaufgabe) und führen Sie eine Zertifizierung der KI nach dem oben kennengelernten KI-Prüfkatalog durch.
- I Betrachten Sie dabei alle Dimensionen
- I Sollten Sie keinen geeigneten Use Case haben (evtl. zu trivial) überlegen Sie sich einen passenden Use Case, z.B. Assistenzsysteme im Auto/ autonomes Fahren.

A5.3.1: Dimension Fairness (2)



Untersuchen Sie die Dimension Fairness (S. 37ff.).

- | Schutzbedarfsanalyse
- | Risikoanalyse
- | Definition von Zielvorgaben
- | Kriterien zur Zielerreichung
- | Maßnahmen
- | Gesamtbewertung
- | Zusammenfassende Betrachtung

Beschreiben Sie die angegebenen Risikogebiete

- | FN (S. 40 ff.)
- | BD (S. 44 ff.)
- | Sind ggf. weitere Risikogebiete relevant?

Seitenzahlen beziehen sich auf: [Poretschkin et al. 2021]

A5.3.1: Dimension Autonomie und Kontrolle (3)



Untersuchen Sie die Dimension Autonomie und Kontrolle (S. 48ff.).

- | Schutzbedarfsanalyse
- | Risikoanalyse
- | Definition von Zielvorgaben
- | Kriterien zur Zielerreichung
- | Maßnahmen
- | Gesamtbewertung
- | Zusammenfassende Betrachtung

Beschreiben Sie die angegebenen Risikogebiete

- | GE (S. 51 ff.)
- | IB (S. 57 ff.)
- | Sind ggf. weitere Risikogebiete relevant?

Seitenzahlen beziehen sich auf: [Poretschkin et al. 2021]

A5.3.1: Dimension Transparenz (4)



Untersuchen Sie die Dimension Transparenz (S. 63 ff.).

- | Schutzbedarfsanalyse
- | Risikoanalyse
- | Definition von Zielvorgaben
- | Kriterien zur Zielerreichung
- | Maßnahmen
- | Gesamtbewertung
- | Zusammenfassende Betrachtung

Beschreiben Sie die angegebenen Risikogebiete

- | NB (S. 67 ff.)
- | EX (S. 72 ff.)
- | AF (S. 79 ff.)
- | BD (S. 83 ff.)
- | Sind ggf. weitere Risikogebiete relevant?

Seitenzahlen beziehen sich auf: [Poretschkin et al. 2021]

A5.3.1: Dimension Verlässlichkeit (5)



Untersuchen Sie die Dimension Verlässlichkeit (S. 86 ff.).

- I Schutzbedarfsanalyse
- I Risikoanalyse
- I Definition von Zielvorgaben
- I Kriterien zur Zielerreichung
- I Maßnahmen
- I Gesamtbewertung
- I Zusammenfassende Betrachtung

Beschreiben Sie die angegebenen Risikogebiete

- I RE (S. 89 ff.)
- I RO (S. 96 ff.)
- I AF (S. 102 ff.)
- I UN (S. 108 ff.)
- I BD (S. 112 ff.)
- I Sind ggf. weitere Risikogebiete relevant?

Seitenzahlen beziehen sich auf: [Poretschkin et al. 2021]

A5.3.1: Dimension Sicherheit (6)



Untersuchen Sie die Dimension Sicherheit (S. 116 ff.).

- | Schutzbedarfsanalyse
- | Risikoanalyse
- | Definition von Zielvorgaben
- | Kriterien zur Zielerreichung
- | Maßnahmen
- | Gesamtbewertung
- | Zusammenfassende Betrachtung

Beschreiben Sie die angegebenen Risikogebiete

- | FS (S. 119 ff.)
- | IV (S. 130 ff.)
- | BD (S. 138 ff.)
- | Sind ggf. weitere Risikogebiete relevant?

Seitenzahlen beziehen sich auf: [Poretschkin et al. 2021]

A5.3.1: Dimension Datenschutz (7)



Untersuchen Sie die Dimension Datenschutz (S. 142 ff.).

- | Schutzbedarfsanalyse
- | Risikoanalyse
- | Definition von Zielvorgaben
- | Kriterien zur Zielerreichung
- | Maßnahmen
- | Gesamtbewertung
- | Zusammenfassende Betrachtung

Beschreiben Sie die angegebenen Risikogebiete

- | PD (S. 146 ff.)
- | GI (S. 152 ff.)
- | BD (S. 158 ff.)
- | Sind ggf. weitere Risikogebiete relevant?

Seitenzahlen beziehen sich auf: [Poretschkin et al. 2021]

A5.3.2: Diskussion und offene Fragen



- Ist eine Zertifizierung nach diesem Muster realistisch und durchführbar?
- Welche offenen Fragen/ ungeklärte Punkte gibt es noch im KI-Zertifizierungsverfahren?
- Welche Regelungen müssen noch getroffen werden, bevor eine KI zertifiziert werden kann?

Zusammenfassung

Zusammenfassung

- I Kritikalitätspyramide als Mittel zur Einsortierung der eigenen Anwendung
- I KI-Prüfkatalog bietet einen Rahmen zur Beurteilung (Zertifizierung) einer KI-Anwendung
 - I Top Down und Bottom-Up
 - I Dimensionen: Fairness, Transparenz, Verlässlichkeit, etc.
- I Bislang existiert keine etablierte Methode zur Zertifizierung einer KI

Literatur

- [Poretschkin et al. 2021] Maximilian Poretschkin et al.: Leitfaden zur Gestaltung vertrauenswürdiger Künstlicher Intelligenz - KI-Prüfkatalog; https://www.iais.fraunhofer.de/content/dam/iais/fb/Kuenstliche_intelligenz/ki-pruefkatalog/202107_KI-Pruefkatalog.pdf
- [Heesen et al. 2020] Jessica Heesen et al.: Zertifizierung von KI-Systemen – Impulspapier; Plattform Lernende Systeme; https://www.plattform-lernende-systeme.de/files/Downloads/Publikationen/AG3_Impulspapier_290420.pdf
- [DIN 2020] Deutsche Normungsroadmap Künstliche Intelligenz; <https://www.dke.de/de/arbeitsfelder/core-safety/normungsroadmap-ki>



Fragen?